

Báo cáo tiến độ Phase 3

Ứng dụng AI trong gán nhãn ảnh y tế cho bệnh đau thắt lưng

Trung Kiên | GVHD: Phan Trọng Nhân

09/09/2026

1. Tóm tắt


Báo cáo tổng hợp kết quả Phase 3, đối chiếu với mốc đã trình bày trước hội đồng ở Phase 2. Ba nhóm việc đã hoàn thành: (i) phần mềm gán nhãn, trong đó **cơ chế** của vòng phản hồi bác sĩ đã được cài đặt và kiểm thử đầy đủ nhưng **chưa từng chạy trên chỉnh sửa thật**, nên báo cáo này không đưa ra con số trước/sau nào cho nó (mục 3.7); (ii) bốn thực nghiệm GPU tìm hướng cải thiện lớp Severe; (iii) chẩn đoán nguyên nhân điểm yếu ở nhãn lỗ liên hợp và một khung đánh giá khả năng diễn giải có kiểm chứng.

Kết quả đáng kể nhất là **chẩn đoán được nguyên nhân** khiến nhãn lỗ liên hợp (*neural foraminal narrowing*) luôn kém: quy trình cắt ảnh cũ lấy vùng ảnh từ chuỗi Sagittal T2 trong khi bác sĩ chấm nhãn này trên Sagittal T1, và đo trong không gian bệnh nhân cho thấy **32,2% (trái) và 47,2% (phải)** vùng cần chấm nằm ngoài độ sâu ảnh mà mô hình được cho. Sau khi cắt riêng theo từng bên trên T1, AUPRC lỗ liên hợp tăng **+0,054** và **+0,039** so với Phase 2.

Báo cáo cũng ghi lại bốn kết quả âm và hai lỗi phương pháp đã phát hiện, vì chúng ảnh hưởng tới cách diễn giải số liệu cũ.


2. Phần mềm gán nhãn

Ứng dụng web (FastAPI + React/Cornerstone3D) cho phép tải ảnh MRI, xem theo lát, chạy mô hình chấm 11 nhãn bất thường, và **ghi nhận chỉnh sửa của bác sĩ như phản hồi chuyên gia**. Quy mô hiện tại: 16.426 dòng Python, 2.452 dòng frontend, 24 tệp kiểm thử.



Hình 1: Màn hình danh sách ca. Mỗi bệnh nhân có thể chứa nhiều lần chụp; trạng thái *Ready* nghĩa là ảnh đã tải xong và sẵn sàng chấm.

Điểm thiết kế đáng lưu ý ở Hình 2: chỉnh sửa của bác sĩ **không tác động ngay** tới mô hình. Chúng được xếp hàng, việc huấn luyện lại chạy ngoại tuyến, và phiên bản mô hình mới phải được duyệt rồi mới kích hoạt. Điều này tránh tình huống kết quả của bệnh nhân sau bị thay đổi bởi chỉnh sửa của bệnh nhân trước.



Hình 2: Màn hình đọc ảnh, hiển thị chuỗi Sagittal T2 ($512 \times 512 \times 17$, $0,586 \times 0,586 \times 3,3$ mm). Bảng *Abnormality grades* nằm dưới ảnh cho phép bác sĩ sửa từng nhãn; khối *Doctor feedback* bên phải gom các chỉnh sửa thành hàng đợi huấn luyện.

3. Vòng phản hồi bác sĩ: phương pháp

Mục 2 mô tả vòng phản hồi ở mức thao tác. Mục này nói phần phương pháp: cơ chế cập nhật là gì, gọi tên thế nào trong tài liệu, đo bằng gì, và hiện đã làm tới đâu.

3.1. Gọi tên cho đúng

Hệ thống là **human-in-the-loop continual learning** dạng **batch/ngoại tuyến**, kịch bản **new-instance (NI)** — cùng bài toán chấm điểm, cùng không gian nhãn, chỉ thêm mẫu mới đã được bác sĩ hiệu chỉnh — cập nhật bằng **rehearsal (replay)** và có **cổng phê duyệt của người**.

Bóc từng vế: kịch bản NI theo bộ ba NI/NC/NIC của Lomonaco và Maltoni (COrE50, CoRL 2017), vì không thêm lớp mới và không thêm tác vụ mới; nhãn cố định *Normal/Mild–Moderate–Severe* nên không phải class-incremental theo phân loại của van de Ven và Tolias (arXiv:1904.07734); vai trò kép của bác sĩ — vừa sinh nhãn vừa gác cổng — là định nghĩa human-in-the-loop trong khảo sát của Budd, Robinson và Kainz (*Medical Image Analysis*, 2021).

Ba cách gọi cần tránh, vì đều sai và đều làm yếu lập luận. Thứ nhất, **không** gọi là *online learning*: online là cập nhật ngay theo từng ca, còn ở đây cố ý gom lô và chạy ngoài giờ — chính cái “cố ý không” đó mới là đóng góp. Thứ hai, **không** gọi trần là *fine-tuning*: fine-tune trần trên vài chục ca là *iterative fine-tuning*, chưa phải continual learning, vì thiếu cơ chế chống quên; thứ nâng nó lên là ba chốt ở mục 3.2. Thứ ba, **không** nhận là *active learning*: active learning là mô hình tự chọn ca nó không chắc để hỏi, còn ở đây bác sĩ tự chọn ca. Đây là phần duy nhất trong phân loại còn thiếu, và nó rẻ vì đầu ra đã có xác suất; xếp vào hướng phát triển.

3.2. Cơ chế cập nhật và ba chốt an toàn


Mô hình gồm hai phần: phần nền ResNet34-3D kèm CBAM (khoảng 63 triệu tham số, “học cách nhìn”) và ba đầu phân loại (khoảng 50 nghìn tham số, “học cách phán”). Với vài chục ca chỉnh sửa, huấn luyện 63 triệu tham số sẽ học thuộc đúng mấy ca đó và quên gần mười nghìn ca RSNA.

Vì vậy cách cập nhật là **chỉ huấn luyện ba đầu, đóng băng phần nền**. Giả định nền là bác sĩ sửa nhãn phần

lớn vì *ngưỡng phán* lệch chứ không phải vì mô hình *nhìn* sai; tỉ lệ 50 nghìn tham số trên vài chục mẫu cũng là tỉ lệ chấp nhận được. Kèm theo là ba chốt, mỗi chốt chặn một kiểu hỏng không phát ra lỗi:

- 1. **Đóng băng BatchNorm.** Đóng băng phần nền chỉ tắt gradient, trong khi BatchNorm cập nhật thống kê *không* qua gradient. Một lô bốn mẫu sẽ đề thống kê tích lũy từ toàn bộ tập huấn luyện. Đây là nguyên nhân đã được ghi nhận của việc quên thảm khốc khi thích nghi mô hình y tế trên tập nhỏ (arXiv:2011.08096).
- 2. **Bộ đệm replay.** Trộn khoảng 200 đĩa đệm gốc vào mỗi lượt cập nhật. Không có nó, mô hình chỉ thấy những ca bị sửa và tưởng dữ liệu thật đều như vậy.
- 3. **Cổng macro-F1.** Chỉ giữ trọng số mới nếu macro-F1 tăng trên tập đánh giá đã đóng băng.

Hình 3 vẽ toàn bộ vòng lặp theo bốn dải: trực tuyến (ứng dụng phục vụ), thu thập (tách “lưu” khỏi “gửi”), ngoại tuyến (huấn luyện lại theo lô và kiểm chứng), và triển khai (người duyệt, có thể hoàn tác). Nét liền là thành phần đã cài đặt và đã kiểm thử; nét đứt là dự kiến — hiện chỉ có hai hộp nét đứt, là *active learning* và *kiểm tra chất lượng nhãn*.



Hình 3: Vòng lặp phản hồi bác sĩ theo cơ chế human-in-the-loop continual learning dạng batch. Nét liền: thành phần đã cài đặt và kiểm thử; nét đứt: dự kiến.

Bảng 1 giải thích vì sao không chọn các hướng cập nhật khác. Lý do chung là ở vùng vài chục mẫu, replay có bằng chứng y tế mạnh nhất, còn các hướng còn lại hoặc cần nhiều mẫu hơn, hoặc cần thành phần mà ứng dụng hiện không chạy.

Bảng 1: Vì sao chọn head-only kèm replay thay cho các hướng cập nhật khác.

Hướng	Lý do không chọn
Head-only + replay + BN đóng băng EWC	Đang dùng. Rẻ, bằng chứng y tế mạnh nhất ở vùng dữ liệu ít Ma trận Fisher cần dữ liệu cũ; ở vài chục mẫu ước lượng không đáng tin. Thử nghiệm trên ảnh da liễu cho thấy replay thắng EWC ở mọi cấu hình
LwF	Bằng chứng y tế mỏng, không mạnh hơn replay
LoRA / adapter	Cần từ 50 mẫu trở lên; thêm phụ thuộc, thừa ở quy mô này
Tip-Adapter / prototype	Không thể quên và hoàn tác tức thì, nhưng cần BiomedCLIP, trong khi ứng dụng đang chạy nhánh CBAM
Huấn luyện lại toàn bộ	Quên thảm khốc khi số mẫu nhỏ

3.3. Chuẩn bị dữ liệu từ chỉnh sửa

Chỉnh sửa của bác sĩ không được dùng trực tiếp. Bước dựng dữ liệu làm bốn việc. Một, khử trùng lặp: mỗi cặp (ca, ô nhân) chỉ lấy lần sửa *mới nhất*, vì bác sĩ có thể sửa đi sửa lại một ô. Hai, chỉ lấy các lô đã gửi, và lấy được theo đúng một mã lô, để một lượt huấn luyện cũ tái lập được chính xác những gì nó từng thấy. Ba, **cắt lại vùng ảnh** từ ảnh gốc và mặt nạ phân vùng bằng đúng hàm mà lúc chấm đã dùng, cho ra khối (9, 112, 224) — không lưu ảnh tại thời điểm sửa, để tránh lệch giữa lúc huấn luyện và lúc phục vụ. Bốn, ô nào bác sĩ không đụng tới thì gán -1 , khớp quy ước *ignore_index* mà nhánh huấn luyện chính đang dùng, nghĩa là không bia nhân cho những đầu ra bác sĩ không nhận xét.

Ngoài dữ liệu chỉnh sửa, một lượt cập nhật còn cần hai tập nữa: tập replay khoảng 200 đĩa đệm gốc, và tập đánh giá đã đóng băng. Cả hai lấy từ bộ RSNA 2024 đã tiền xử lý.

Lượt cập nhật thứ hai trở đi lấy dữ liệu từ đâu. Đây là một quyết định dễ bị bỏ qua nhưng quyết định luôn việc cơ chế có trôi hay không. Kiến thức cũ tích lũy ở *trọng số*: mỗi lượt nạp checkpoint đang phục vụ rồi tinh chỉnh tiếp, nên lượt thứ hai xuất phát từ kết quả của lượt thứ nhất. Nhưng *dữ liệu* thì không tự tích lũy. Nếu mỗi lượt chỉ huấn luyện trên lô mới, các chỉnh sửa của lô trước không còn xuất hiện trong tập huấn luyện, chúng chỉ còn tồn tại gián tiếp trong trọng số — đúng dạng trôi kinh điển của continual learning: chạy theo cái sửa mới nhất và để những cái đã sửa trước đó phai dần. Tập replay không bù được, vì 200 đĩa đệm đó là dữ liệu RSNA gốc, tức neo mô hình về *phân phối ban đầu* chứ không neo về những gì bác sĩ đã phán.

Do đó mặc định là **huấn luyện tích lũy**: mỗi lượt dùng toàn bộ chỉnh sửa đã gửi từ trước tới nay, để bản cập nhật nào cũng phải thỏa mãn mọi điều bác sĩ từng sửa. Mã lô vẫn được giữ, nhưng cho mục đích khác — ghi sổ và tái lập chính xác một lượt chạy cũ — và vẫn có thể chạy theo đúng một lô khi cần đối chứng. Việc một ô bị sửa nhiều lần ở các lô khác nhau không gây trùng lặp, vì bước dựng dữ liệu chỉ giữ bản sửa mới nhất của mỗi cặp (ca, ô nhân).

Cách này có hai cái giá phải nói rõ. Thứ nhất, tập huấn luyện **phình dần** theo từng lượt; tới một quy mô nào đó thì lập luận “vài chục mẫu nên chỉ chỉnh ba đầu phân loại” ở mục 3.2 không còn đứng vững, và phải xét lại phương pháp cập nhật. Thứ hai, nó **buộc mọi chỉnh sửa cũ phải được thỏa mãn vô thời hạn**; nếu một bác sĩ đọc lệch thì cái lệch đó bị đóng đinh, và như mục 3.6 đã nêu, chỉnh sửa của bác sĩ không phải chân lý — mức đồng thuận giữa hai người đọc trên thang Pfirrmann chỉ vào khoảng $\kappa = 0,68$. Hai giới hạn này thuộc phần cần theo dõi khi vòng lặp thực sự chạy nhiều lượt.

3.4. Giao thức đánh giá và cổng chặn

Tập đánh giá được **chốt trước khi thu thập bất kỳ chỉnh sửa nào**: 200 dòng, đóng băng ngày 26/07/2026, kèm tệp kê khai ghi SHA-256 của các dòng đã chọn cùng hạt giống và thời điểm, và có lệnh kiểm tra lại để chứng minh tập không đổi. Điều này bắt buộc chứ không phải cho chặt chẽ: nếu chọn tập đánh giá *sau* khi đã biết bác sĩ sửa những đĩa nào, con số đo được phản ánh cách chọn chứ không phản ánh mô hình, và không có cách nào dựng lại bảo đảm đó về sau.

Chỉ tiêu quyết định là **macro-F1**, không phải độ chính xác. Lớp *Severe* hiếm, nên một mô hình sập về đoán

Normal/Mild cho mọi ô vẫn đạt độ chính xác trung bình cao trong khi mất hết giá trị lâm sàng — đúng lớp mà đề tài sinh ra để cải thiện. Trọng số mới chỉ được ghi ra tệp khi macro-F1 sau lớn hơn trước; không đạt thì bỏ, và tệp trọng số giữ lại có những sẵn số đo trước/sau để người duyệt nhìn số mà quyết.

3.5. Vì sao “theo lô, ngoại tuyến, có người duyệt” là thiết kế đúng

Hướng dẫn của FDA tháng 12/2024 về *Predetermined Change Control Plan* (PCCP) cho phần mềm y tế dùng trí tuệ nhân tạo cho phép nhà sản xuất khai báo trước phạm vi thay đổi — tần suất, giới hạn dữ liệu, quy trình kiểm chứng, cách hoàn tác — và sau đó cập nhật trong phạm vi đó mà không phải xin duyệt lại từ đầu. Điểm mấu chốt là hướng dẫn này áp cho **cập nhật theo lô, ngoại tuyến**, không áp cho học trực tuyến liên tục. Đạo luật AI của Liên minh châu Âu, hiệu lực 01/08/2024, cùng quy định về thiết bị y tế cũng đòi có giám sát của người và hậu kiểm.

Nghĩa là thiết kế “gom lô, chạy ngoài giờ, người bấm duyệt, hoàn tác được” không phải làm cho đơn giản mà là làm cho đúng khung quản lý. Đây là lập luận nên nói thẳng khi bảo vệ, vì nó biến một điểm trông như hạn chế thành một lựa chọn có căn cứ.

3.6. Chỉnh sửa của bác sĩ không phải chân lý

Một nghiên cứu ba người đọc trên ảnh MRI thất lưng thoái hoá cho thấy chỉ số đồng thuận Cohen’s κ với thang Pfirrmann chỉ đạt 0,68, tức hai bác sĩ bất đồng khoảng một phần ba số ca. Do đó việc một bác sĩ sửa nhãn của mô hình không đương nhiên có nghĩa mô hình sai, và nuốt toàn bộ chỉnh sửa vào tập huấn luyện có nguy cơ dạy mô hình thiên theo cách đọc của một người.

Hướng xử lý theo *confident learning* (Northcutt, Jiang và Chuang, JAIR 2021) là đánh dấu những chỉnh sửa mâu thuẫn với dự đoán mà mô hình đang rất tự tin để xem lại, thay vì đưa thẳng vào huấn luyện. Lý tưởng là mỗi ca có ít nhất hai bác sĩ đọc độc lập; nếu không có thì phải ghi vào phần hạn chế. Cơ chế truy vết cần thiết thì ứng dụng đã có sẵn: mỗi lần lưu tạo một phiên bản chú giải mới và mỗi ô thay đổi được ghi một dòng nhật ký riêng.

3.7. Đã làm tới đâu, và điều không được phép hứa

Phần cơ chế đã cài đặt và có kiểm thử: dựng dữ liệu từ lô, huấn luyện lại đầu phân loại kèm ba chốt, đóng băng tập đánh giá, cố macro-F1, và sổ đăng ký mô hình cho phép kích hoạt lần hoàn tác. Các chốt được kiểm thử theo hướng chứng minh *hồng thật khi bỏ chốt*, chẳng hạn có một kiểm thử cho thấy thống kê BatchNorm trôi nếu không đóng băng.

Ba phần còn thiếu, nêu ra để không bị hiểu nhầm là đã xong. Một, giao thức thống kê mới có phần đo trước/sau, **chưa có** kiểm định McNemar, khoảng tin cậy bootstrap cho $\Delta F1$, và chỉ số backward transfer để đo quên (Lopez-Paz và Ranzato, NeurIPS 2017) — tức hiện đủ sức *chặn* một bản cập nhật tệ nhưng chưa đủ sức *khẳng định* một bản tốt. Hai, hàm mất mát đang dùng entropy chéo trần, chưa có trọng số lớp, trong khi chính cấu hình này đã từng làm lớp *Severe* sập về F1 bằng 0 ở một thực nghiệm trước; cố macro-F1 sẽ chặn hậu quả, nhưng nếu chạy mà không cải thiện thì việc đầu tiên nên thử là thêm trọng số lớp. Ba, và đây là giới hạn đáng kể nhất về phạm vi: **chỉ ba trong mười một nhãn có thể học được từ chỉnh sửa**. Bước dựng dữ liệu chỉ ánh xạ ba đầu phân loại của mô hình CBAM; một chỉnh sửa trên tám nhãn còn lại — vốn do nhánh SpineNet gốc sinh ra — vẫn được ghi nhật ký, vẫn vào lô, vẫn được đếm là “đã gửi”, rồi bị bỏ qua khi dựng tập huấn luyện. Nói cách khác, giao diện cho bác sĩ sửa nhiều hơn những gì vòng lặp tiêu thụ được. Giao diện vận hành hiện đã đánh dấu các nhãn này, nhưng khoảng cách đó là có thật và chỉ đóng lại được khi tám nhãn kia cũng được huấn luyện trong cùng một khung.

Quan trọng nhất: **vòng lặp chưa chạy trên chỉnh sửa thật của bác sĩ**, nên báo cáo này không đưa ra con số trước/sau nào. Và ngay cả khi chạy, với quy mô 20–50 mẫu thì **không thể chứng minh mô hình tốt lên một cách có ý nghĩa thống kê** — các công trình continual learning trong ảnh y tế dùng cỡ 100–1000 mẫu, còn vùng 20–50 chưa được kiểm chứng, và ngưỡng tối thiểu để một con số macro-F1 bảo vệ được là khoảng 50–100 mẫu *cho riêng lớp thiếu số*.

Vì vậy phát biểu mà phần này nhắm tới không phải “phản hồi của bác sĩ làm mô hình tốt lên” mà là “cơ chế cập nhật an toàn, không gây quên, có cổng kiểm duyệt của người và có thể hoàn tác”. Khi có số, câu kết luận đúng đắn sẽ có dạng: cơ chế không gây quên, có xu hướng cải thiện lớp đang yếu với khoảng tin cậy kèm theo, và cỡ mẫu chưa đủ để kết luận có ý nghĩa thống kê.

4. Mốc Phase 2 đã trình bày hội đồng

4.1. Bốn cấu hình nội bộ

Bảng 2 là số đã báo cáo, giữ nguyên để đối chiếu.

Bảng 2: Bốn cấu hình trên RSNA 2024 (seed 42), số đã trình bày ở Phase 2.

Chỉ số	SpineNetV2	CBAM	BMC-only	Hybrid
Mean Accuracy	0,814	0,690	0,692	0,721
Mean F1 (macro)	0,420	0,502	0,464	0,528
Mean AUC	0,826	0,822	0,812	0,837
<i>Lớp Severe</i>				
Severe Recall	0,115	0,370	0,245	0,464
Severe F1	0,149	0,304	0,229	0,343
Severe AUPRC	0,276	0,319	0,218	0,321

4.2. So sánh với phương pháp ngoài

Hai phương pháp ngoài được huấn luyện lại trên **đúng cùng phép chia bệnh nhân** (seed 42/123/456, chia 80/20 theo mã ca) và đánh giá trên cùng ba nhãn, để so sánh công bằng.

Bảng 3: Các cấu hình đem so sánh.

Cấu hình	Kiến trúc	Nguồn
SpineNetV2	3D-ResNet34	nền so sánh của đề tài
brendanartley	CNN 2.5D + BiLSTM + gộp có chú ý	hạng nhì RSNA 2024, cài đặt lại
transformer	CNN 2.5D + bộ mã hoá Transformer	kiểu gộp Transformer 2024
Hybrid	CBAM-3D + BiomedCLIP, đầu ra theo mô tả văn bản	của đề tài

Bảng 4: Kết quả trên RSNA 2024, trung bình ± độ lệch chuẩn qua 3 seed.

Chỉ số	SpineNetV2	brendanartley	transformer	Hybrid
Mean Accuracy (%)	81,0 ± 0,6	83,6 ± 0,5	83,4 ± 0,4	72,4 ± 0,3
Mean F1 (macro)	0,420 ± 0,010	0,532 ± 0,008	0,527 ± 0,028	0,527 ± 0,027
<i>Lớp Severe — lớp có ý nghĩa lâm sàng</i>				
Severe F1	0,152 ± 0,008	0,271 ± 0,026	0,257 ± 0,020	0,356 ± 0,017
Severe Recall (%)	12,3 ± 0,6	26,0 ± 1,6	25,9 ± 2,8	48,6 ± 1,9

Bảng 4 cho thấy một sự đánh đổi rõ ràng. Hybrid **thua khoảng 11 điểm Accuracy** và ngang bằng về Mean F1, nhưng ở lớp Severe thì dẫn đầu rõ rệt: Severe Recall **48,6%** so với 26,0% và 25,9%, tức **gần gấp đôi** phương pháp ngoài tốt nhất; Severe F1 **0,356** so với 0,271.

Đánh đổi này là có chủ ý. Hai phương pháp ngoài đạt Accuracy cao bằng cách thiên về lớp đa số (Normal/Mild chiếm phần lớn dữ liệu), trong khi ca bỏ sót ở lớp Severe mới là ca gây hậu quả lâm sàng. Với bài toán sàng lọc, bỏ sót ba trong bốn ca nặng để đổi lấy Accuracy đẹp hơn là đánh đổi sai hướng.

Ngoài chỉ số, Hybrid còn có ba khả năng mà cả ba phương pháp kia đều không có, do chúng dùng đầu ra cố định:

Bảng 5: So sánh khả năng mở rộng tập nhãn.

Khả năng	SpineNetV2	2 phương pháp ngoài	Hybrid
Nhận tập nhãn mới làm đầu vào	không	không	có
Chuyển sang bộ dữ liệu khác (SPIDER)	phải huấn luyện lại	phải huấn luyện lại	có
Dự đoán nhãn chưa từng thấy	không	không	có

Ghi chú về tính công bằng của phép so sánh. Hai phương pháp ngoài là **cài đặt lại phần lõi kiến trúc chấm điểm**, đã điều chỉnh để nhận cùng dạng vùng ảnh (9, 112, 224) của đề tài — **không phải** pipeline đầu-cuối từ ảnh DICOM của tác giả gốc. Cả hai cũng huấn luyện từ đầu vì không có trọng số tiền huấn luyện tương thích, trong khi Hybrid dùng backbone đã tiền huấn luyện. Con số vì vậy phản ánh so sánh kiến trúc trên cùng biểu diễn dữ liệu, không phải so sánh hai hệ thống hoàn chỉnh.

5. Thực nghiệm Phase 3

5.1. Sửa lỗi khởi tạo: nền so sánh sạch

Hai thực nghiệm trước đó dùng nhằm checkpoint khởi tạo (không có trọng số lớp). Chạy lại đúng công thức đã công bố trên checkpoint đúng cho kết quả ở Bảng 6. Đây là **sửa lỗi, không phải đóng góp** — giá trị của nó là mọi so sánh về sau không bị bác bằng câu “nền so sánh của em hỏng”.

Bảng 6: Cùng công thức, khác checkpoint khởi tạo (seed 42, cùng tập validation).

Chỉ số	Phase 2	Khởi tạo đúng	Chênh
Severe AUPRC	0,3211	0,3696	+0,0485
Severe F1	0,3434	0,3696	+0,0262
Mean Accuracy	0,7208	0,7318	+0,0110
Mean F1 (macro)	0,5277	0,5286	+0,0009
Macro AUPRC	0,5258	0,5364	+0,0106
Macro AUC	0,8371	0,8368	−0,0003

Bảng 7 tách theo từng nhãn, và đây mới là chỗ giải thích vì sao phải làm bước tiếp theo.

Bảng 7: Kết quả từng nhãn, Phase 2 so với khởi tạo đúng (seed 42, cùng tập validation).

	Phase 2	Khởi tạo đúng	Chênh
<i>Ổng sống</i>			
Severe F1	0,5000	0,5714	+0,0714
Severe Recall	0,7037	0,8395	+0,1358
AUPRC	0,6284	0,6506	+0,0222
<i>Lỗi liên hợp trái</i>			
AUPRC	0,4670	0,4709	+0,0039
Severe F1	0,2778	0,2887	+0,0109
<i>Lỗi liên hợp phải</i>			
AUPRC	0,4820	0,4878	+0,0058
Severe F1	0,2524	0,2486	−0,0038

Ổng sống cải thiện rõ (Severe Recall **+0,136**), nhưng **hai nhãn lỗi liên hợp gần như đứng yên** — AUPRC chỉ nhích 0,004 và 0,006. Sửa khởi tạo không chạm được tới điểm yếu này, nghĩa là nguyên nhân nằm ở chỗ khác. Đó là điều dẫn tới phần tiếp theo.

5.2. Chuyên gia T1 cho nhãn lỗ liên hợp: đóng góp chính

Chẩn đoán. Đối chiếu tệp tọa độ với mô tả chuỗi ảnh: nhãn lỗ liên hợp được chấm **100% trên Sagittal T1**, nhãn ống sống **99,9% trên Sagittal T2**, và hai loại chỉ dùng chung một chuỗi **1 lần trên 6291** ca. Quy trình cũ cắt một vùng ảnh duy nhất từ T2 lấy tâm theo tọa độ ống sống rồi gắn cả ba nhãn.

Đo độ lệch trong **không gian bệnh nhân** của DICOM (dùng ImagePositionPatient và ImageOrientationPatient, không so tọa độ điểm ảnh vì hai chuỗi có lưới khác nhau):

Bảng 8: Vị trí nhãn lỗ liên hợp so với vùng ảnh cắt từ T2 (796 cặp, 80 ca).

	Lỗ trái	Lỗ phải
Lệch trong mặt phẳng (trung vị)	9,7 mm	9,9 mm
Nằm ngoài khung ảnh theo mặt phẳng	0,3%	0,3%
Lệch theo chiều sâu (trung vị)	4,0 lát	4,0 lát
Nằm ngoài độ sâu 9 lát	32,2%	47,2%

Khung ảnh theo mặt phẳng rất rộng (nửa cạnh 70×35 mm) nên hầu như luôn phủ được. Chỗ hụt là **độ sâu**: vùng ảnh chỉ gồm 9 lát, trong khi gần một nửa số ca bên phải có vùng cần chấm nằm ngoài phạm vi đó. Nói cách khác, mô hình được yêu cầu chấm một cấu trúc **không có trong ảnh đầu vào**.

Kết quả sau khi sửa. Cắt vùng ảnh riêng cho từng bên trên chuỗi T1, lấy tâm theo tọa độ của chính bên đó:

Bảng 9: AUPRC nhãn lỗ liên hợp. Cột “đỉnh” là epoch tốt nhất trong 20 epoch.

	Phase 2	Chuyên gia T1	Chênh	Đỉnh ep16
<i>AUPRC — chỉ số xếp hạng, không phụ thuộc ngưỡng</i>				
Lỗ trái	0,4670	0,5205	+0,054	0,5321
Lỗ phải	0,4820	0,5209	+0,039	0,5311
<i>AUC</i>				
Lỗ trái	0,7880	0,8165	+0,029	0,8281
Lỗ phải	0,7964	0,8147	+0,018	0,8268
<i>Severe F1 — phụ thuộc ngưỡng argmax</i>				
Lỗ trái	0,2778	0,2247	-0,053	—
Lỗ phải	0,2524	0,2902	+0,038	—

Severe F1 lỗ trái lại giảm, và điều này cần giải thích chứ không nên bỏ qua. AUPRC tăng trong khi F1 giảm nghĩa là mô hình **xếp hạng ca nặng tốt hơn nhưng điểm cắt argmax chưa khai thác được lợi thế đó**. Đây đúng là việc mà tinh chỉnh ngưỡng giải quyết: đo bằng kiểm chéo theo nửa bệnh nhân, chỉnh trọng số quyết định từng lớp nâng macro F1 từ 0,468 lên **0,509 (+0,041)** trên phần dữ liệu giữ lại. Trên mô hình Phase 2 cùng phương pháp cho **+0,019**. Hai cải thiện này cộng dồn được vì chúng tác động vào hai khâu khác nhau — một cái cải thiện biểu diễn, một cái cải thiện quy tắc quyết định.

Điều đáng tin hơn con số: **cả 20/20 epoch** của mô hình T1 đều vượt epoch tốt nhất trong 20 epoch của mô hình cũ, ở cả hai bên, không ngoại lệ. Tính nhất quán này loại trừ khả năng vớ được một epoch may.

Kiểm chứng nguyên nhân. Nếu vùng ảnh thật sự không thấy được lỗ liên hợp thì mô hình cũ phải kém hơn ở đúng những ca đó. Kiểm trong nội bộ một mô hình, chia theo một thuộc tính của dữ liệu mà mô hình không biết:

Bảng 10: AUC lớp Severe của mô hình T2, chia theo vị trí nhãn.

	Trong 9 lát	Ngoài 9 lát	Chênh	p
Lỗ phải	0,8983	0,8321	+0,066	0,044
Lỗ trái	0,8685	0,8643	+0,004	0,903

Bên phải xác nhận, bên trái không. Hai bên khác nhau theo đúng hướng dự đoán: bên phải có 47,2% ca ngoài phạm vi so với 32,2% của bên trái, tức nhiều ca bị ảnh hưởng hơn thì hiệu ứng lớn hơn. **Giới hạn cần nêu:** đây là hai phép kiểm, một cái đạt $p = 0,044$; hiệu chỉnh cho việc so nhiều lần thì $p = 0,088$, nên kết luận đúng là **có dấu hiệu ủng hộ**, chưa phải bằng chứng chắc chắn.

5.3. Một bằng chứng độc lập: mức đồng thuận so với bác sĩ

Chẩn đoán ở trên dựa vào hình học và vào kết quả của mô hình. Có một cách kiểm tra thứ ba, không dùng cả hai: so **mức đồng thuận** của mô hình với mức đồng thuận **giữa các bác sĩ với nhau**, đo bằng cùng một chỉ số là Cohen's kappa có trọng số bậc hai (QWK).

Bảng 11: QWK của mô hình Phase 2 so với đồng thuận giữa bác sĩ (Lurie và cộng sự, *Spine*, 2008).

	Mô hình	Giữa các bác sĩ
Ổng sống	0,641	0,73
Lỗ liên hợp trái	0,351	0,58
Lỗ liên hợp phải	0,409	0,58

Mô hình **gần chạm mức bác sĩ ở ống sống** (0,641 so với 0,73) nhưng **kém xa ở lỗ liên hợp** (0,351 so với 0,58). Đáng chú ý là kết luận này đến từ một hướng hoàn toàn khác — không dùng toạ độ, không dùng hình học, không dùng bản đồ nhiệt — mà vẫn chỉ đúng một chỗ yếu. Ba phép đo độc lập cùng chỉ vào nhãn lỗ liên hợp thì khó quy cho ngẫu nhiên.

Toàn bộ chỉ số của Phase 2 kèm khoảng tin cậy bootstrap phân cụm theo bệnh nhân (2000 lần rút):

Bảng 12: Mô hình Phase 2, khoảng tin cậy 95% phân cụm theo bệnh nhân.

Chỉ số	Giá trị	KTC 95%
Severe F1	0,3434	[0,292 — 0,392]
Severe AUPRC	0,3211	[0,280 — 0,371]
Severe Recall	0,4640	[0,399 — 0,532]
QWK	0,4670	[0,432 — 0,499]
Weighted log loss	0,7549	[0,736 — 0,773]

Khoảng tin cậy của Severe F1 rộng **0,100** — đây là lý do báo cáo dùng AUPRC làm chỉ số chính khi so hai mô hình: với chỉ 80 ca nặng mỗi nhãn, Severe F1 không đủ độ phân giải để phân định, còn AUPRC ổn định hơn khoảng sáu lần giữa các epoch.

5.4. Bốn hướng đã thử và không hiệu quả

Các kết quả âm dưới đây đều đáng báo cáo vì chúng loại bỏ những hướng nghe hợp lý.

Bảng 13: Các hướng cải thiện đã thử nghiệm và kết quả.

Hướng	Kết quả
Cơ chế trộn có cổng (gated fusion)	Chênh lệch đỉnh 0,0016, nhỏ hơn độ lệch chuẩn giữa các epoch (0,0048). Không khác biệt.
Trung bình trọng số nhiều epoch	Kém hơn epoch đơn tốt nhất ở mọi chỉ số. Không có tác dụng.
Mở băng tầng cuối của backbone	Quá khớp: Mean Accuracy +0,029 nhưng Severe AUPRC -0,037 . Quá khớp ăn vào lớp hiểm trước.
Bản đồ nhiệt (Grad-CAM) để định vị	Thua phép đoán “giữa ảnh”: 30,7 mm so với 21,6 mm. Không định vị được.

Kết quả mở băng backbone trở thành **lý lẽ bảo vệ** thiết kế đóng băng hiện tại, khi được hỏi “tại sao không tinh chỉnh toàn bộ mạng”.

6. Khả diễn giải: khảo sát và kiểm chứng

Theo yêu cầu khảo sát nhiều hướng tiếp cận, đã rà 16 phương pháp thuộc bốn họ: CAM dùng gradient, CAM không gradient, quy gán ở không gian đầu vào, và tín hiệu nội tại của mô hình. Chọn triển khai bốn phương pháp có **cơ chế khác nhau** thay vì nhiều biến thể cùng một cơ chế.

Hai kết quả kiểm chứng đáng lưu:

Grad-CAM trên nhánh CBAM là phân rã chính xác, không phải suy đoán. Đầu ra của mạng là gộp trung bình toàn cục rồi một tầng tuyến tính — đúng kiến trúc mà Draelos & Carin chứng minh CAM, HiResCAM và Grad-CAM cho cùng một kết quả. Kiểm bằng số trên mô hình của đề tài: tương quan Pearson **1,000000**, sai lệch tuyệt đối lớn nhất $2,4 \times 10^{-7}$.

Bản đồ nhiệt không định vị được lỗ liên hợp. Đo khoảng cách từ đỉnh bản đồ nhiệt tới điểm bác sĩ chấm, kèm hai mốc đối chứng bắt buộc:

Bảng 14: Khoảng cách tới điểm bác sĩ chấm (trung vị, mm), các ca Severe.

	Lỗ trái (n=53)	Lỗ phải (n=20)
Grad-CAM	30,7	33,9
Layer-CAM	31,8	30,4
Đoán ngẫu nhiên	49,7	53,7
Đoán giữa ảnh	21,6	19,6

Cả hai phương pháp thắng phép đoán ngẫu nhiên nhưng **thua phép đoán “giữa ảnh”**, nên chúng không mang thông tin định vị hữu ích. Kết quả này trùng với Arun và cộng sự (*Radiology: AI*, 2021): cả 8 phương pháp họ thử trên ảnh y tế thật đều trượt ít nhất một tiêu chí tin cậy.

Hệ quả cần ghi nhận: hình Grad-CAM dùng trong bài báo đã nộp **không chứng minh được** điều nó tuyên bố. Vùng ống sống nằm ngay giữa ảnh do cách cắt, nên “mô hình tập trung vào ống sống” không phân biệt được với “mô hình tập trung vào giữa ảnh” — mốc đối chứng cho 0,4 mm trong khi Grad-CAM cho 14,0 mm.

7. Hai lỗi phương pháp đã phát hiện

Sai hệ toạ độ. Phép đo hình học ban đầu trừ toạ độ điểm ảnh của hai chuỗi T1 và T2 như thể chúng cùng một hệ. Ba trong bốn ca kiểm tra có lưới ảnh khác nhau (384×384 ở 0,78 mm so với 640×640 ở 0,47 mm). Tính lại trong không gian bệnh nhân thì lập luận vẫn đúng nhưng **đổi trục**: không phải “ngoài khung hình” mà là “ngoài độ sâu 9 lát”.

Sai phép chia tập bệnh nhân. Hàm chia chạy trên danh sách bệnh nhân của từng tập mô tả dữ liệu; hai tập lệch nhau 3 ca nên sinh ra hai phép chia hoàn toàn khác nhau. Hai tập validation chỉ chung 214 trên 395 bệnh nhân, và 181 bệnh nhân nằm ở tập kiểm của mô hình này lại nằm ở tập huấn luyện của mô hình kia. Việc này **không làm sai** số của từng mô hình, nhưng làm phép **so sánh** giữa chúng lỏng hơn mức đã trình bày. Đã sửa bằng cách chia theo hàm băm mã bệnh nhân, cho 406 bệnh nhân trùng khớp 100% giữa hai tập dữ liệu.

8. Kế hoạch tiếp theo

1. **Ghép hệ định tuyến đầu-cuối** — lấy nhãn ống sống từ nhánh T2 và nhãn lỗ liên hợp từ nhánh T1 thành một hệ thống. Không cần huấn luyện lại, chỉ cần nối dự đoán theo khoá (ca, tầng). Cho ra Mean F1 macro ba điều kiện để đặt cạnh Phase 2 — con số hiện còn thiếu.
2. **Chạy 3 seed** cho cấu hình thắng, vì mọi số Phase 3 hiện là một seed trong khi Phase 2 dùng 3 seed. Không được trộn hai bộ số trong cùng một bảng.

3. **Quy công giữa hai nhánh** — do mô hình chỉ có hai nhánh nên giá trị Shapley tính được chính xác tuyệt đối chỉ với hai lượt suy luận thêm. Trả lời được nhánh nào quyết định kết quả.
4. **Sửa số liệu trong luận văn** — câu ở phần tóm tắt hiện ghi “Mean F1 macro từ 0,343 lên 0,474”; 0,343 thực chất là Severe F1, còn 0,474 không khớp tệp số liệu nào. Số đúng theo 3 seed là **0,4202** → **0,5265**, Severe Recall **12,3%** → **48,6%**.
5. **Hoàn thiện phần mềm** — quay video minh họa, và xử lý phản hồi của thầy.