

Báo cáo tiến độ Phase 3

Ứng dụng AI trong gắn nhãn ảnh y tế cho bệnh đau thắt lưng

Trung Kiên | GVHD: Phan Trọng Nhân

21/09/2026

Mục lục

1	Tóm tắt	1
2	Phần mềm gắn nhãn	2
3	Vòng phản hồi bác sĩ: phương pháp	2
3.1	Gọi tên cho đúng	2
3.2	Cơ chế cập nhật và ba chốt an toàn	3
3.3	Chuẩn bị dữ liệu từ chỉnh sửa	7
3.4	Giao thức đánh giá và cổng chặn	7
3.5	Vì sao “theo lô, ngoại tuyến, có người duyệt” là thiết kế đúng	7
3.6	Chỉnh sửa của bác sĩ không phải chân lý	8
3.7	Đã làm tới đâu, và điều không được phép hứa	8
4	So sánh với phương pháp ngoài	8
5	Thực nghiệm Phase 3	11
5.1	Sửa lỗi khởi tạo: nền so sánh sạch	11
5.2	Chuyên gia T1 cho nhãn lỗi liên hợp: hướng chính, chưa kết luận	11
5.3	Bốn hướng đã thử và không hiệu quả	13
6	Khả diễn giải: khảo sát và kiểm chứng	13
7	Hội nghị MIWAI 2026: tài liệu đã chuẩn bị	14
8	Số liệu chi tiết các phase trước	14
8.1	Bốn cấu hình nội bộ	14
8.2	Chi tiết theo từng bệnh và từng mức độ	14
9	Ba lỗi phương pháp đã phát hiện	16
10	Kế hoạch tiếp theo	16

1. Tóm tắt

Báo cáo tổng hợp kết quả Phase 3, đối chiếu với mốc đã trình bày trước hội đồng ở Phase 2. Ba nhóm việc đã hoàn thành: (i) phần mềm gắn nhãn, trong đó **cơ chế** của vòng phản hồi bác sĩ đã được cài đặt và kiểm thử đầy đủ nhưng **chưa từng chạy trên chỉnh sửa thật**, nên báo cáo này không đưa ra con số trước/sau nào


cho nó (mục 3.7); (ii) bốn thực nghiệm GPU tìm hướng cải thiện lớp Severe; (iii) chẩn đoán nguyên nhân điểm yếu ở nhãn lỗ liên hợp và một khung đánh giá khả năng diễn giải có kiểm chứng.

Kết quả đáng kể nhất là **chẩn đoán được nguyên nhân** khiến nhãn lỗ liên hợp (*neural foraminal narrowing*) luôn kèm: quy trình cắt ảnh cũ lấy vùng ảnh từ chuỗi Sagittal T2 trong khi bác sĩ chấm nhãn này trên Sagittal T1, và đo trong không gian bệnh nhân cho thấy **32,2% (trái) và 47,2% (phải)** vùng cần chấm nằm ngoài độ sâu ảnh mà mô hình được cho. Sau khi cắt riêng theo từng bên trên T1, AUPRC lỗ liên hợp tăng **+0,054** và **+0,039** so với Phase 2.

Báo cáo cũng ghi lại bốn kết quả âm và hai lỗi phương pháp đã phát hiện, vì chúng ảnh hưởng tới cách diễn giải số liệu cũ.

2. Phần mềm gán nhãn

Ứng dụng web (FastAPI + React/Cornerstone3D) cho phép tải ảnh MRI, xem theo lát, chạy mô hình chấm 11 nhãn bất thường, và **ghi nhận chỉnh sửa của bác sĩ như phản hồi chuyên gia**. Quy mô hiện tại: 16.426 dòng Python, 2.452 dòng frontend, 24 tệp kiểm thử.



Hình 1: Màn hình danh sách ca. Mỗi bệnh nhân có thể chứa nhiều lần chụp; trạng thái *Ready* nghĩa là ảnh đã tải xong và sẵn sàng chấm.

Điểm thiết kế đáng lưu ý ở Hình 2: chỉnh sửa của bác sĩ **không tác động ngay** tới mô hình. Chúng được xếp hàng, việc huấn luyện lại chạy ngoại tuyến, và phiên bản mô hình mới phải được duyệt rồi mới kích hoạt. Điều này tránh tình huống kết quả của bệnh nhân sau bị thay đổi bởi chỉnh sửa của bệnh nhân trước.


3. Vòng phản hồi bác sĩ: phương pháp

Mục 2 mô tả vòng phản hồi ở mức thao tác. Mục này nói phần phương pháp: cơ chế cập nhật là gì, gọi tên thế nào trong tài liệu, đo bằng gì, và hiện đã làm tới đâu.

3.1. Gọi tên cho đúng

Hệ thống là **human-in-the-loop continual learning** dạng **batch/ngoại tuyến**, kịch bản **new-instance (NI)** — cùng bài toán chấm điểm, cùng không gian nhãn, chỉ thêm mẫu mới đã được bác sĩ hiệu chỉnh — cập nhật bằng **rehearsal (replay)** và có **cổng phê duyệt của người**.

Bóc từng vế: kịch bản NI theo bộ ba NI/NC/NIC của Lomonaco và Maltoni (CRe50, CoRL 2017), vì không thêm lớp mới và không thêm tác vụ mới; nhãn cố định *Normal/Mild–Moderate–Severe* nên không phải class-incremental theo phân loại của van de Ven và Tolias (arXiv:1904.07734); vai trò kép của bác sĩ — vừa sinh nhãn vừa gác cổng — là định nghĩa human-in-the-loop trong khảo sát của Budd, Robinson và Kainz (*Medical Image Analysis*, 2021).



Hình 2: Màn hình đọc ảnh, hiển thị chuỗi Sagittal T2 ($512 \times 512 \times 17$, $0,586 \times 0,586 \times 3,3$ mm). Bảng *Abnormality grades* nằm dưới ảnh cho phép bác sĩ sửa từng nhãn; khối *Doctor feedback* bên phải gom các chỉnh sửa thành hàng đợi huấn luyện.

Ba cách gọi cần tránh, vì đều sai và đều làm yếu lập luận. Thứ nhất, **không** gọi là *online learning*: online là cập nhật ngay theo từng ca, còn ở đây cố ý gom lô và chạy ngoài giờ — chính cái “cố ý không” đó mới là đóng góp. Thứ hai, **không** gọi trần là *fine-tuning*: fine-tune trần trên vài chục ca là *iterative fine-tuning*, chưa phải continual learning, vì thiếu cơ chế chống quên; thứ nâng nó lên là ba chốt ở mục 3.2. Thứ ba, **không** nhận là *active learning*: active learning là mô hình tự chọn ca nó không chắc để hỏi, còn ở đây bác sĩ tự chọn ca. Đây là phần duy nhất trong phân loại còn thiếu, và nó rẻ vì đầu ra đã có xác suất; xếp vào hướng phát triển.


3.2. Cơ chế cập nhật và ba chốt an toàn

Mô hình gồm hai phần: phần nền ResNet34-3D kèm CBAM (khoảng 63 triệu tham số, “học cách nhìn”) và ba đầu phân loại (khoảng 50 nghìn tham số, “học cách phán”). Với vài chục ca chỉnh sửa, huấn luyện 63 triệu tham số sẽ học thuộc đúng mấy ca đó và quên gần mười nghìn ca RSNA.

Vì vậy cách cập nhật là **chỉ huấn luyện ba đầu, đóng băng phần nền**. Giả định nền là bác sĩ sửa nhãn phần lớn vì *ngưỡng phán* lệch chứ không phải vì mô hình *nhìn* sai; tỉ lệ 50 nghìn tham số trên vài chục mẫu cũng là tỉ lệ chấp nhận được. Kèm theo là ba chốt, mỗi chốt chặn một kiểu hỏng không phát ra lỗi:

1. **Đóng băng BatchNorm.** Đóng băng phần nền chỉ tắt gradient, trong khi BatchNorm cập nhật thống kê *không* qua gradient. Một lô bốn mẫu sẽ đề thống kê tích lũy từ toàn bộ tập huấn luyện. Đây là nguyên nhân đã được ghi nhận của việc quên thảm khốc khi thối nghi mô hình y tế trên tập nhỏ (arXiv:2011.08096).
2. **Bộ đệm replay.** Trộn khoảng 200 đĩa đệm gốc vào mỗi lượt cập nhật. Không có nó, mô hình chỉ thấy những ca bị sửa và tưởng dữ liệu thật đều như vậy.
3. **Cổng macro-F1.** Chỉ giữ trọng số mới nếu macro-F1 tăng trên tập đánh giá đã đóng băng.

Hình 3 vẽ toàn bộ vòng lặp theo bốn dải: trực tuyến (ứng dụng phục vụ), thu thập (tách “lưu” khỏi “gửi”), ngoại tuyến (huấn luyện lại theo lô và kiểm chứng), và triển khai (người duyệt, có thể hoàn tác). Nét liền là thành phần đã cài đặt và đã kiểm thử; nét đứt là dự kiến — hiện chỉ có hai hộp nét đứt, là *active learning* và *kiểm tra chất lượng nhãn*.




Nét liền = đã cài đặt và có kiểm thử — nét đứt — dự kiến, chưa có cam = điểm con người tham gia

Cập nhật theo LÔ (batch), không phải online: model đang phục vụ KHÔNG tự đổi khi bác sĩ bấm Lưu — khớp khung FDA PCCP 12/2024.

Hình 3: Vòng lặp phản hồi bác sĩ theo cơ chế human-in-the-loop continual learning dạng batch. Nét liền: thành phần đã cài đặt và kiểm thử; nét đứt: dự kiến.

Hình 4 là cùng vòng lặp đó, tiếng Anh và gọn hơn, **bỏ hẳn hai hộp dự kiến**. Một sơ đồ dùng để trình bày cái đang có thì không nên dành một phần ba bề ngang cho cái chưa có; bản đầy đủ ở Hình 3 vẫn giữ để đối chiếu.



Hình 4: Bản rút gọn tiếng Anh. Mọi hộp trong hình đều đã cài đặt và có kiểm thử; màu cam là điểm có người tham gia.

Bảng 1 giải thích vì sao không chọn các hướng cập nhật khác. Lý do chung là ở vùng vài chục mẫu, replay có bằng chứng y tế mạnh nhất, còn các hướng còn lại hoặc cần nhiều mẫu hơn, hoặc cần thành phần mà ứng dụng hiện không chạy.

Bảng 1: Vì sao chọn head-only kèm replay thay cho các hướng cập nhật khác.

Hướng	Lý do không chọn
Head-only + replay + BN đóng băng EWC	Đang dùng. Rẻ, bằng chứng y tế mạnh nhất ở vùng dữ liệu ít Ma trận Fisher cần dữ liệu cũ; ở vài chục mẫu ước lượng không đáng tin. Thực nghiệm trên ảnh da liễu cho thấy replay thắng EWC ở mọi cấu hình
LwF	Bằng chứng y tế mỏng, không mạnh hơn replay
LoRA / adapter	Cần từ 50 mẫu trở lên; thêm phụ thuộc, thừa ở quy mô này
Tip-Adapter / prototype	Không thể quên và hoàn tác tức thì, nhưng cần BiomedCLIP, trong khi ứng dụng đang chạy nhánh CBAM
Huấn luyện lại toàn bộ	Quên thảm khốc khi số mẫu nhỏ

Cách đang dùng có tên gọi hay tự nghĩ ra? Không có phần nào tự nghĩ ra. Đây là tổ hợp ba thành phần đều đã chuẩn hoá trong y văn: **tinh chỉnh chỉ phần đầu** trên xương sống đóng băng (linear probing), **bộ đệm replay** (rehearsal) trộn mẫu cũ vào mỗi lượt, và mô hình triển khai **theo lô, ngoại tuyến, có người duyệt** đúng khung mà giới y tế dùng cho mô hình học liên tục. Đóng góp nếu có không nằm ở thuật toán mà ở chỗ ráp ba thứ đó vào một ứng dụng chạy được, kèm tập đánh giá đóng băng và cơ chế hoàn tác. Điều này là *có chủ ý*: ở vùng vài chục mẫu, hướng đơn giản nhất lại là hướng có bằng chứng y tế mạnh nhất, nên chọn nó

thay vì phát minh là lựa chọn phòng thủ được.

Cơ chế từng hướng bị loại, và vì sao không hợp.

EWC (Kirkpatrick và cộng sự, PNAS 2017) sau khi học xong nhiệm vụ cũ sẽ ước lượng ma trận thông tin Fisher — đo mức nhạy của hàm mất mát theo từng trọng số — rồi thêm một phạt bậc hai kéo các trọng số *quan trọng với nhiệm vụ cũ* ở lại gần giá trị cũ. Không hợp ở đây vì hai lẽ. Ước lượng Fisher cần dữ liệu cũ và một siêu tham số cường độ phạt, trong khi đề tài không có ngân sách dữ liệu để dò siêu tham số đó. Và quan trọng hơn: phạt chỉ bảo vệ những trọng số *đang được huấn luyện*, mà ở đây chỉ có 50 nghìn tham số đầu phân loại — phần replay đã bảo vệ rồi. Thực nghiệm trên ảnh da liễu cho thấy replay thắng EWC ở mọi cấu hình.

LwF (Li và Hoiem, TPAMI 2018) giữ một bản sao mô hình cũ, rồi khi huấn luyện trên dữ liệu mới thì buộc đầu ra của mô hình mới *trên chính dữ liệu mới* đó bám theo đầu ra của mô hình cũ. Ưu điểm là không cần giữ dữ liệu cũ. Nhưng đó cũng chính là lý do nó không hợp: **đề tài có giữ dữ liệu cũ** (một cơ sở, tập huấn luyện nằm trong tay), nên lý do tồn tại của LwF không áp dụng. Tệ hơn, dữ liệu mới ở đây *là những ca mô hình cũ chầm sai* — chứng cất theo đầu ra cũ trên đúng những ca đó là dạy lại chính cái sai cần sửa.

LoRA và adapter đóng băng xương sống rồi chèn các ma trận hạng thấp vào trong, huấn luyện riêng phần chèn đó. Mục đích là *thêm sức chứa* khi một đầu tuyến tính không đủ. Ở vài chục mẫu thì vấn đề không phải thiếu sức chứa mà là thiếu dữ liệu: thêm sức chứa chỉ làm khớp thừa nhanh hơn. Các báo cáo dùng được thường bắt đầu từ khoảng 50 mẫu trở lên, và nó kéo theo siêu tham số mới (hạng, hệ số, chèn ở tầng nào) mà không có tập nào để dò.

Tip-Adapter và các hướng nguyên mẫu dựng một bộ nhớ đệm gồm các cặp (đặc trưng, nhãn) từ số mẫu ít ỏi, rồi lúc suy luận thì trộn điểm số zero-shot với một phiếu bầu có trọng số theo độ tương đồng với bộ nhớ đó. Hướng này **rất hấp dẫn cho đúng bài toán này**: không cần huấn luyện, và xoá một mục khỏi bộ nhớ là hiệu ứng biến mất tức thì — tức quên và hoàn tác gần như miễn phí. Lý do không dùng thuần túy kỹ thuật: nó cần không gian nhúng ảnh–văn bản kiểu CLIP, tức cần BiomedCLIP, trong khi đường suy luận của ứng dụng đang chạy nhánh CBAM. Dùng được thì phải phục vụ một mô hình khác.

Huấn luyện lại toàn bộ 63 triệu tham số trên vài chục mẫu trộn vào gần mười nghìn mẫu cũ rơi vào một trong hai kết cục: hoặc gần như không đổi gì, hoặc nếu tăng trọng số cho mẫu mới thì quên thảm khốc. Kèm theo là chi phí tính toán và gánh nặng kiểm chứng lại toàn bộ.

Bảng 1 bàn về *cập nhật thế nào*. Còn một trục thứ hai đã khảo sát là *chọn ca nào cho bác sĩ xem trước*, tức active learning. Trục này hiện **chưa cài đặt**, nhưng các hướng đều đã có quyết định rõ ràng nên ghi lại ở Bảng 2.

Bảng 2: Trục chọn mẫu (active learning): đã khảo sát, chưa cài đặt.

Hướng	Kết luận
Lấy mẫu theo độ bất định	Rẻ nhất và được hậu thuẫn tốt nhất cho phân loại ảnh y tế (Gal, Islam và Ghahramani, ICML 2017). Là hướng sẽ chọn nếu cài trục này
Query-by-committee, coreset	Đẹp về học thuật nhưng quá tốn cho một GPU đơn ở quy mô mẫu nhỏ (Sener và Savarese, ICLR 2018). Loại
Rủi ro khởi đầu lạnh	Nhóm mẫu ban đầu nhỏ hoặc thiên lệch có thể làm active learning tệ hơn chọn ngẫu nhiên (COLoSAL, MICCAI 2023). Phải nêu như một hạn chế nếu cài

Công cụ gần nhất đã có sẵn ngoài kia là MONAI Label (Diaz-Pinto và cộng sự, *Medical Image Analysis*, 2024): cùng hạng mục với ứng dụng của đề tài, cũng tính độ bất định để xếp thứ tự ca cho người đọc. Khác biệt của ứng dụng này nằm ở phần sau vòng lặp — tập đánh giá đóng băng, cổng macro-F1 và sổ đăng ký cho phép hoàn tác — chứ không nằm ở phần chọn mẫu.

3.3. Chuẩn bị dữ liệu từ chỉnh sửa

Chỉnh sửa của bác sĩ không được dùng trực tiếp. Bước dựng dữ liệu làm bốn việc. Một, khử trùng lặp: mỗi cặp (ca, ô nhân) chỉ lấy lần sửa *mới nhất*, vì bác sĩ có thể sửa đi sửa lại một ô. Hai, chỉ lấy các lô đã gửi, và lấy được theo đúng một mã lô, để một lượt huấn luyện cũ tái lập được chính xác những gì nó từng thấy. Ba, **cắt lại vùng ảnh** từ ảnh gốc và mặt nạ phân vùng bằng đúng hàm mà lúc chấm đã dùng, cho ra khối (9, 112, 224) — không lưu ảnh tại thời điểm sửa, để tránh lệch giữa lúc huấn luyện và lúc phục vụ. Bốn, ô nào bác sĩ không đụng tới thì gán -1 , khớp quy ước *ignore_index* mà nhánh huấn luyện chính đang dùng, nghĩa là không bịa nhãn cho những đầu ra bác sĩ không nhận xét.

Ngoài dữ liệu chỉnh sửa, một lượt cập nhật còn cần hai tập nữa: tập replay khoảng 200 đĩa đệm gốc, và tập đánh giá đã đóng băng. Cả hai lấy từ bộ RSNA 2024 đã tiền xử lý.

Lượt cập nhật thứ hai trở đi lấy dữ liệu từ đâu. Đây là một quyết định dễ bị bỏ qua nhưng quyết định luôn việc cơ chế có trôi hay không. Kiến thức cũ tích lũy ở *trọng số*: mỗi lượt nạp checkpoint đang phục vụ rồi tinh chỉnh tiếp, nên lượt thứ hai xuất phát từ kết quả của lượt thứ nhất. Nhưng *dữ liệu* thì không tự tích lũy. Nếu mỗi lượt chỉ huấn luyện trên lô mới, các chỉnh sửa của lô trước không còn xuất hiện trong tập huấn luyện, chúng chỉ còn tồn tại gián tiếp trong trọng số — đúng dạng trôi kinh điển của continual learning: chạy theo cái sửa mới nhất và để những cái đã sửa trước đó phai dần. Tập replay không bù được, vì 200 đĩa đệm đó là dữ liệu RSNA gốc, tức neo mô hình về *phân phối ban đầu* chứ không neo về những gì bác sĩ đã phán.

Do đó mặc định là **huấn luyện tích lũy**: mỗi lượt dùng toàn bộ chỉnh sửa đã gửi từ trước tới nay, để bản cập nhật nào cũng phải thỏa mãn mọi điều bác sĩ từng sửa. Mã lô vẫn được giữ, nhưng cho mục đích khác — ghi sổ và tái lập chính xác một lượt chạy cũ — và vẫn có thể chạy theo đúng một lô khi cần đối chứng. Việc một ô bị sửa nhiều lần ở các lô khác nhau không gây trùng lặp, vì bước dựng dữ liệu chỉ giữ bản sửa mới nhất của mỗi cặp (ca, ô nhân).

Cách này có hai cái giá phải nói rõ. Thứ nhất, tập huấn luyện **phình dần** theo từng lượt; tới một quy mô nào đó thì lập luận “vài chục mẫu nên chỉ chỉnh ba đầu phân loại” ở mục 3.2 không còn đứng vững, và phải xét lại phương pháp cập nhật. Thứ hai, nó **buộc mọi chỉnh sửa cũ phải được thỏa mãn vô thời hạn**; nếu một bác sĩ đọc lệch thì cái lệch đó bị đóng đinh, và như mục 3.6 đã nêu, chỉnh sửa của bác sĩ không phải chân lý — mức đồng thuận giữa hai người đọc trên thang Pfirrmann chỉ vào khoảng $\kappa = 0,68$. Hai giới hạn này thuộc phần cần theo dõi khi vòng lặp thực sự chạy nhiều lượt.

3.4. Giao thức đánh giá và cổng chặn

Tập đánh giá được **chốt trước khi thu thập bất kỳ chỉnh sửa nào**: 200 dòng, đóng băng ngày 26/07/2026, kèm tệp kê khai ghi SHA-256 của các dòng đã chọn cùng hạt giống và thời điểm, và có lệnh kiểm tra lại để chứng minh tập không đổi. Điều này bắt buộc chứ không phải cho chặt chẽ: nếu chọn tập đánh giá *sau* khi đã biết bác sĩ sửa những đĩa nào, con số đo được phản ánh cách chọn chứ không phản ánh mô hình, và không có cách nào dựng lại bảo đảm đó về sau.

Chỉ tiêu quyết định là **macro-F1**, không phải độ chính xác. Lớp *Severe* hiếm, nên một mô hình sập về đoán *Normal/Mild* cho mọi ô vẫn đạt độ chính xác trung bình cao trong khi mất hết giá trị lâm sàng — đúng lớp mà đề tài sinh ra để cải thiện. Trọng số mới chỉ được ghi ra tệp khi macro-F1 sau lớn hơn trước; không đạt thì bỏ, và tệp trọng số giữ lại có nhúng sẵn số đo trước/sau để người duyệt nhìn số mà quyết.

3.5. Vì sao “theo lô, ngoại tuyến, có người duyệt” là thiết kế đúng

Hướng dẫn của FDA tháng 12/2024 về *Predetermined Change Control Plan* (PCCP) cho phần mềm y tế dùng trí tuệ nhân tạo cho phép nhà sản xuất khai báo trước phạm vi thay đổi — tần suất, giới hạn dữ liệu, quy trình kiểm chứng, cách hoàn tác — và sau đó cập nhật trong phạm vi đó mà không phải xin duyệt lại từ đầu. Điểm mấu chốt là hướng dẫn này áp cho **cập nhật theo lô, ngoại tuyến**, không áp cho học trực tuyến liên tục. Đạo luật AI của Liên minh châu Âu, hiệu lực 01/08/2024, cùng quy định về thiết bị y tế cũng đòi có giám sát của người và hậu kiểm.

Nghĩa là thiết kế “gom lô, chạy ngoài giờ, người bấm duyệt, hoàn tác được” không phải làm cho đơn giản mà là làm cho đúng khung quản lý. Đây là lập luận nên nói thẳng khi bảo vệ, vì nó biến một điểm trông như hạn chế thành một lựa chọn có căn cứ.

3.6. Chỉnh sửa của bác sĩ không phải chân lý

Một nghiên cứu ba người đọc trên ảnh MRI thất lưng thoái hoá cho thấy chỉ số đồng thuận Cohen’s κ với thang Pfirrmann chỉ đạt 0,68, tức hai bác sĩ bất đồng khoảng một phần ba số ca. Do đó việc một bác sĩ sửa nhãn của mô hình không đương nhiên có nghĩa mô hình sai, và nuốt toàn bộ chỉnh sửa vào tập huấn luyện có nguy cơ dạy mô hình thiên theo cách đọc của một người.

Hướng xử lý theo *confident learning* (Northcutt, Jiang và Chuang, JAIR 2021) là đánh dấu những chỉnh sửa mâu thuẫn với dự đoán mà mô hình đang rất tự tin để xem lại, thay vì đưa thẳng vào huấn luyện. Lý tưởng là mỗi ca có ít nhất hai bác sĩ đọc độc lập; nếu không có thì phải ghi vào phần hạn chế. Cơ chế truy vết cần thiết thì ứng dụng đã có sẵn: mỗi lần lưu tạo một phiên bản chú giải mới và mỗi ô thay đổi được ghi một dòng nhật ký riêng.

3.7. Đã làm tới đâu, và điều không được phép hứa

Phần cơ chế đã cài đặt và có kiểm thử: dựng dữ liệu từ lô, huấn luyện lại đầu phân loại kèm ba chốt, đóng băng tập đánh giá, cổng macro-F1, và sổ đăng ký mô hình cho phép kích hoạt lần hoàn tác. Các chốt được kiểm thử theo hướng chứng minh *hồng thật khi bỏ chốt*, chẳng hạn có một kiểm thử cho thấy thống kê BatchNorm trôi nếu không đóng băng.

Ba phần còn thiếu, nêu ra để không bị hiểu nhầm là đã xong. Một, giao thức thống kê mới có phần đo trước/sau, **chưa có** kiểm định McNemar, khoảng tin cậy bootstrap cho $\Delta F1$, và chỉ số backward transfer để đo quên (Lopez-Paz và Ranzato, NeurIPS 2017) — tức hiện đủ sức *chặn* một bản cập nhật tệ nhưng chưa đủ sức *khẳng định* một bản tốt. Hai, hàm mất mát đang dùng entropy chéo trần, chưa có trọng số lớp, trong khi chính cấu hình này đã từng làm lớp *Severe* sập về F1 bằng 0 ở một thực nghiệm trước; cổng macro-F1 sẽ chặn hậu quả, nhưng nếu chạy mà không cải thiện thì việc đầu tiên nên thử là thêm trọng số lớp. Ba, và đây là giới hạn đáng kể nhất về phạm vi: **chỉ ba trong mười một nhãn có thể học được từ chỉnh sửa**. Bước dựng dữ liệu chỉ ánh xạ ba đầu phân loại của mô hình CBAM; một chỉnh sửa trên tám nhãn còn lại — vốn do nhánh SpineNet gốc sinh ra — vẫn được ghi nhật ký, vẫn vào lô, vẫn được đếm là “đã gửi”, rồi bị bỏ qua khi dựng tập huấn luyện. Nói cách khác, giao diện cho bác sĩ sửa nhiều hơn những gì vòng lặp tiêu thụ được. Giao diện vận hành hiện đã đánh dấu các nhãn này, nhưng khoảng cách đó là có thật và chỉ đóng lại được khi tám nhãn kia cũng được huấn luyện trong cùng một khung.

Quan trọng nhất: **vòng lặp chưa chạy trên chỉnh sửa thật của bác sĩ**, nên báo cáo này không đưa ra con số trước/sau nào. Và ngay cả khi chạy, với quy mô 20–50 mẫu thì **không thể chứng minh mô hình tốt lên một cách có ý nghĩa thống kê** — các công trình continual learning trong ảnh y tế dùng cỡ 100–1000 mẫu, còn vùng 20–50 chưa được kiểm chứng, và ngưỡng tối thiểu để một con số macro-F1 bảo vệ được là khoảng 50–100 mẫu *cho riêng lớp thiếu số*.

Vì vậy phát biểu mà phần này nhắm tới không phải “phản hồi của bác sĩ làm mô hình tốt lên” mà là “cơ chế cập nhật an toàn, không gây quên, có cổng kiểm duyệt của người và có thể hoàn tác”. Khi có số, câu kết luận đúng đắn sẽ có dạng: cơ chế không gây quên, có xu hướng cải thiện lớp đang yếu với khoảng tin cậy kèm theo, và cỡ mẫu chưa đủ để kết luận có ý nghĩa thống kê.

4. So sánh với phương pháp ngoài

Hai phương pháp ngoài được huấn luyện lại trên **đúng cùng phép chia bệnh nhân** (seed 42/123/456, chia 80/20 theo mã ca) và đánh giá trên cùng ba nhãn, để so sánh công bằng.

Hai phương pháp ngoài làm gì. Cả hai đều theo lối **2.5D**: thay vì tích chập xuyên qua chiều lát cắt, chúng mã hoá *từng lát một* bằng một mạng 2D rồi mới gộp chín vectơ thu được. Khác nhau ở cách gộp.

Bảng 3: Các cấu hình đem so sánh.

Cấu hình	Cách xử lý chiều lát cắt	Nguồn
SpineNetV2	tích chập 3D	nền so sánh của đề tài
CNN-BiLSTM	2.5D: mã hoá từng lát, gộp bằng BiLSTM	theo giải nhì RSNA 2024 (brendanartley)
CNN-Transformer	2.5D: mã hoá từng lát, gộp bằng tự chú ý	kiểu ViT, dựng làm đối chứng thứ hai
Hybrid	tích chập 3D + tiên nghiệm văn bản	của đề tài

CNN-BiLSTM, theo giải nhì RSNA 2024. Mỗi lát trong chín lát sagittal đi qua một bộ mã hoá ResNet18 riêng, cho ra một chuỗi chín vectơ. Chuỗi này được đưa qua **BiLSTM** — mạng hồi tiếp hai chiều, đọc xuôi và đọc ngược để mỗi lát biết ngữ cảnh cả hai phía — rồi **gộp có chú ý** thu chuỗi về một vectơ duy nhất, với trọng số do chính mô hình học. Cuối cùng là ba đầu tuyến tính độc lập, mỗi đầu ba lớp.

CNN-Transformer. Cùng bộ mã hoá ResNet18 theo từng lát, nhưng chín vectơ được coi là chín *token*. Thêm một token [CLS] học được và nhúng vị trí, rồi cho cả mười token qua một bộ mã hoá Transformer nhỏ; đầu ra tại vị trí [CLS] là biểu diễn của cả khối. Đây là lối ViT quen thuộc, áp lên một chuỗi lát cắt ngắn thay vì các mảnh ảnh, và là lựa chọn *không hồi tiếp* đặt cạnh BiLSTM ở trên để hai đối chứng khác nhau về cơ chế chứ không chỉ khác tên.

Khác biệt cốt lõi so với đề tài nằm ở hai chỗ. Một, cả hai chỉ nhìn xuyên lát *sau khi* đã mã hoá xong từng lát, trong khi mô hình của đề tài tích chập 3D nên thấy quan hệ giữa các lát ngay từ tầng đầu. Hai, cả hai kết thúc bằng **đầu phân loại cố định**, nên không thể nhận tập nhãn mới — đó là nguồn gốc của Bảng 8 bên dưới.

Bảng 4: Kết quả trên RSNA 2024, trung bình $\pm$ độ lệch chuẩn qua 3 seed.

Chỉ số	SpineNetV2	CNN-BiLSTM	CNN-Transformer	Hybrid
Mean Accuracy (%)	81,0 $\pm$ 0,6	83,6 $\pm$ 0,5	83,4 $\pm$ 0,4	72,4 $\pm$ 0,3
Mean F1 (macro)	0,420 $\pm$ 0,010	0,532 $\pm$ 0,008	0,527 $\pm$ 0,028	0,527 $\pm$ 0,027
<i>Lớp Severe — lớp có ý nghĩa lâm sàng</i>				
Severe F1	0,152 $\pm$ 0,008	0,271 $\pm$ 0,026	0,257 $\pm$ 0,020	0,356 $\pm$ 0,017
Severe Recall (%)	12,3 $\pm$ 0,6	26,0 $\pm$ 1,6	25,9 $\pm$ 2,8	48,6 $\pm$ 1,9

Bảng 4 cho thấy một sự đánh đổi rõ ràng. Hybrid **thua khoảng 11 điểm Accuracy** và ngang bằng về Mean F1, nhưng ở lớp Severe thì dẫn đầu rõ rệt: Severe Recall **48,6%** so với 26,0% và 25,9%, tức **gần gấp đôi** phương pháp ngoài tốt nhất; Severe F1 **0,356** so với 0,271.

Đánh đổi này là có chủ ý. Hai phương pháp ngoài đạt Accuracy cao bằng cách thiên về lớp đa số (Normal/Mild chiếm phần lớn dữ liệu), trong khi ca bỏ sót ở lớp Severe mới là ca gây hậu quả lâm sàng. Với bài toán sàng lọc, bỏ sót ba trong bốn ca nặng để đổi lấy Accuracy đẹp hơn là đánh đổi sai hướng.

Nhưng con số gộp che mất một điều đáng kể. Bảng 6 và Bảng 7 tách tiếp theo từng điều kiện và từng lớp. Ở lớp Severe:

Bảng 5: Severe F1 theo từng điều kiện, trung bình $\pm$ độ lệch chuẩn qua 3 seed.

Điều kiện	SpineNetV2	CNN-BiLSTM	CNN-Transformer	Hybrid
Ổng sống	0,433	0,688	0,683	0,501
Lỗ trái	0,022	0,088	0,059	0,292
Lỗ phải	0,000	0,037	0,030	0,273

Đọc theo hàng thì bức tranh đảo chiều hai lần. **Ở ống sống, hai phương pháp ngoài thắng Hybrid rõ rệt** — 0,688 và 0,683 so với 0,501. Nhưng ở hai lỗ liên hợp thì chúng gần như **không làm được gì**: Severe F1 rơi xuống 0,037 và 0,030 bên phải, trong khi Hybrid giữ được 0,273. Riêng SpineNetV2 đạt đúng **0,000 ở cả ba seed** — chưa một lần dự đoán Severe cho lỗ phải.

Nghĩa là **toàn bộ lợi thế gộp của Hybrid đến từ hai nhãn lỗi liên hợp**, còn ở nhãn ống sống thì nó đang thua. Nói thẳng điều này có lợi hơn là để con số gộp nói thay, vì nó khớp với phần còn lại của báo cáo: lỗi liên hợp là chỗ *mọi* mô hình đều gặp khó do ảnh đầu vào không chứa đủ thông tin (mục 5.2), và tiên nghiệm ngữ nghĩa đóng băng của Hybrid là thứ giữ nó không sụp hẳn ở đó. Đổi lại, ở nhãn mà ảnh đã đủ thông tin thì một mô hình 2.5D chuyên biệt vẫn tốt hơn.

Bảng 6: F1 theo điều kiện $\times$ lớp, trung bình $\pm$ độ lệch chuẩn qua 3 seed.

Điều kiện	Lớp	SpineNetV2	CNN-BiLSTM	CNN-Transformer	Hybrid
Ống sống	Normal/Mild	$0,944 \pm 0,003$	$0,969 \pm 0,004$	$0,967 \pm 0,003$	$0,945 \pm 0,007$
	Moderate	$0,119 \pm 0,011$	$0,476 \pm 0,021$	$0,469 \pm 0,073$	$0,323 \pm 0,159$
	Severe	$0,433 \pm 0,016$	$0,688 \pm 0,025$	$0,683 \pm 0,028$	$0,501 \pm 0,064$
Lỗ trái	Normal/Mild	$0,878 \pm 0,004$	$0,889 \pm 0,007$	$0,889 \pm 0,002$	$0,764 \pm 0,032$
	Moderate	$0,252 \pm 0,062$	$0,372 \pm 0,086$	$0,402 \pm 0,098$	$0,421 \pm 0,042$
	Severe	$0,022 \pm 0,039$	$0,088 \pm 0,031$	$0,059 \pm 0,051$	$0,292 \pm 0,017$
Lỗ phải	Normal/Mild	$0,869 \pm 0,001$	$0,890 \pm 0,001$	$0,887 \pm 0,006$	$0,775 \pm 0,019$
	Moderate	$0,264 \pm 0,015$	$0,380 \pm 0,056$	$0,360 \pm 0,138$	$0,443 \pm 0,010$
	Severe	$0,000 \pm 0,000$	$0,037 \pm 0,023$	$0,030 \pm 0,033$	$0,273 \pm 0,022$

Bảng 7: Recall theo điều kiện $\times$ lớp, trung bình $\pm$ độ lệch chuẩn qua 3 seed.

Điều kiện	Lớp	SpineNetV2	CNN-BiLSTM	CNN-Transformer	Hybrid
Ống sống	Normal/Mild	$0,986 \pm 0,000$	$0,979 \pm 0,004$	$0,971 \pm 0,002$	$0,937 \pm 0,012$
	Moderate	$0,071 \pm 0,008$	$0,410 \pm 0,025$	$0,432 \pm 0,104$	$0,307 \pm 0,195$
	Severe	$0,355 \pm 0,022$	$0,710 \pm 0,027$	$0,727 \pm 0,108$	$0,698 \pm 0,029$
Lỗ trái	Normal/Mild	$0,963 \pm 0,012$	$0,945 \pm 0,027$	$0,936 \pm 0,021$	$0,650 \pm 0,044$
	Moderate	$0,178 \pm 0,057$	$0,315 \pm 0,117$	$0,359 \pm 0,133$	$0,645 \pm 0,061$
	Severe	$0,012 \pm 0,021$	$0,051 \pm 0,021$	$0,032 \pm 0,028$	$0,417 \pm 0,043$
Lỗ phải	Normal/Mild	$0,948 \pm 0,006$	$0,956 \pm 0,017$	$0,951 \pm 0,025$	$0,668 \pm 0,036$
	Moderate	$0,197 \pm 0,017$	$0,308 \pm 0,073$	$0,305 \pm 0,154$	$0,665 \pm 0,046$
	Severe	$0,000 \pm 0,000$	$0,020 \pm 0,013$	$0,016 \pm 0,018$	$0,343 \pm 0,027$

Ngoài chỉ số, Hybrid còn có ba khả năng mà cả ba phương pháp kia đều không có, do chúng dùng đầu ra cố định:

Bảng 8: So sánh khả năng mở rộng tập nhãn.

Khả năng	SpineNetV2	2 phương pháp ngoài	Hybrid
Nhận tập nhãn mới làm đầu vào	không	không	có
Chuyển sang bộ dữ liệu khác (SPIDER)	phải huấn luyện lại	phải huấn luyện lại	có
Dự đoán nhãn chưa từng thấy	không	không	có

Ghi chú về tính công bằng của phép so sánh. Hai phương pháp ngoài là **cài đặt lại phần lõi kiến trúc chấm điểm**, đã điều chỉnh để nhận cùng dạng vùng ảnh (9, 112, 224) của đề tài — **không phải** pipeline đầu-cuối từ ảnh DICOM của tác giả gốc. Cả hai cũng huấn luyện từ đầu vì không có trọng số tiền huấn luyện tương thích, trong khi Hybrid dùng backbone đã tiền huấn luyện. Con số vì vậy phản ánh so sánh kiến trúc trên cùng biểu diễn dữ liệu, không phải so sánh hai hệ thống hoàn chỉnh.

5. Thực nghiệm Phase 3

5.1. Sửa lỗi khởi tạo: nền so sánh sạch

Hai thực nghiệm trước đó dùng nhầm checkpoint khởi tạo (không có trọng số lớp). Chạy lại đúng công thức đã công bố trên checkpoint đúng cho kết quả ở Bảng 9. Đây là **sửa lỗi, không phải đóng góp** — giá trị của nó là mọi so sánh về sau không bị bác bằng câu “nền so sánh của em hỏng”.

Bảng 9: Cùng công thức, khác checkpoint khởi tạo (seed 42, cùng tập validation).

Chỉ số	Phase 2	Khởi tạo đúng	Chênh
Severe AUPRC	0,3211	0,3696	+0,0485
Severe F1	0,3434	0,3696	+0,0262
Mean Accuracy	0,7208	0,7318	+0,0110
Mean F1 (macro)	0,5277	0,5286	+0,0009
Macro AUPRC	0,5258	0,5364	+0,0106
Macro AUC	0,8371	0,8368	−0,0003

Bảng 10 tách theo từng nhãn, và đây mới là chỗ giải thích vì sao phải làm bước tiếp theo.

Bảng 10: Kết quả từng nhãn, Phase 2 so với khởi tạo đúng (seed 42, cùng tập validation).

	Phase 2	Khởi tạo đúng	Chênh
<i>Ổng sống</i>			
Severe F1	0,5000	0,5714	+0,0714
Severe Recall	0,7037	0,8395	+0,1358
AUPRC	0,6284	0,6506	+0,0222
<i>Lỗ liên hợp trái</i>			
AUPRC	0,4670	0,4709	+0,0039
Severe F1	0,2778	0,2887	+0,0109
<i>Lỗ liên hợp phải</i>			
AUPRC	0,4820	0,4878	+0,0058
Severe F1	0,2524	0,2486	−0,0038

Ổng sống cải thiện rõ (Severe Recall **+0,136**), nhưng **hai nhãn lỗ liên hợp gần như đứng yên** — AUPRC chỉ nhích 0,004 và 0,006. Sửa khởi tạo không chạm được tới điểm yếu này, nghĩa là nguyên nhân nằm ở chỗ khác. Đó là điều dẫn tới phần tiếp theo.

5.2. Chuyên gia T1 cho nhãn lỗ liên hợp: hướng chính, chưa kết luận

Chẩn đoán. Đối chiếu tập toạ độ với mô tả chuỗi ảnh: nhãn lỗ liên hợp được chấm **100% trên Sagittal T1**, nhãn ống sống **99,9% trên Sagittal T2**, và hai loại chỉ dùng chung một chuỗi **1 lần trên 6291** ca. Quy trình cũ cắt một vùng ảnh duy nhất từ T2 lấy tâm theo toạ độ ống sống rồi gắn cả ba nhãn.

Đo độ lệch trong **không gian bệnh nhân** của DICOM (dùng ImagePositionPatient và ImageOrientationPatient, không so toạ độ điểm ảnh vì hai chuỗi có lưới khác nhau):

Khung ảnh theo mặt phẳng rất rộng (nửa cạnh 70×35 mm) nên hầu như luôn phủ được. Chỗ hụt là **độ sâu**: vùng ảnh chỉ gồm 9 lát, trong khi gần một nửa số ca bên phải có vùng cần chấm nằm ngoài phạm vi đó. Nói cách khác, mô hình được yêu cầu chấm một cấu trúc **không có trong ảnh đầu vào**.

Kết quả sau khi sửa. Cắt vùng ảnh riêng cho từng bên trên chuỗi T1, lấy tâm theo toạ độ của chính bên đó:

Severe F1 lỗ trái lại giảm, và điều này cần giải thích chứ không nên bỏ qua. AUPRC tăng trong khi F1 giảm nghĩa là mô hình **xếp hạng ca nặng tốt hơn nhưng điểm cắt argmax chưa khai thác được lợi thế đó**. Đây đúng là việc mà tinh chỉnh ngưỡng giải quyết: đo bằng kiểm chéo theo nửa bệnh nhân, chính trọng

Bảng 11: Vị trí nhãn lỗi liên hợp so với vùng ảnh cắt từ T2 (796 cặp, 80 ca).

	Lỗi trái	Lỗi phải
Lệch trong mặt phẳng (trung vị)	9,7 mm	9,9 mm
Nằm ngoài khung ảnh theo mặt phẳng	0,3%	0,3%
Lệch theo chiều sâu (trung vị)	4,0 lát	4,0 lát
Nằm ngoài độ sâu 9 lát	32,2%	47,2%

Bảng 12: AUPRC nhãn lỗi liên hợp. Cột “đỉnh” là epoch tốt nhất trong 20 epoch.

	Phase 2	Chuyên gia T1	Chênh	Đỉnh ep16
<i>AUPRC — chỉ số xếp hạng, không phụ thuộc ngưỡng</i>				
Lỗi trái	0,4670	0,5205	+0,054	0,5321
Lỗi phải	0,4820	0,5209	+0,039	0,5311
<i>AUC</i>				
Lỗi trái	0,7880	0,8165	+0,029	0,8281
Lỗi phải	0,7964	0,8147	+0,018	0,8268
<i>Severe F1 — phụ thuộc ngưỡng argmax</i>				
Lỗi trái	0,2778	0,2247	−0,053	—
Lỗi phải	0,2524	0,2902	+0,038	—

số quyết định từng lớp nâng macro F1 từ 0,468 lên **0,509 (+0,041)** trên phần dữ liệu giữ lại. Trên mô hình Phase 2 cùng phương pháp cho **+0,019**. Hai cải thiện này cộng dồn được vì chúng tác động vào hai khâu khác nhau — một cái cải thiện biểu diễn, một cái cải thiện quy tắc quyết định.

Điều đáng tin hơn con số: **cả 20/20 epoch** của mô hình T1 đều vượt epoch tốt nhất trong 20 epoch của mô hình cũ, ở cả hai bên, không ngoại lệ. Tính nhất quán này loại trừ khả năng vớ được một epoch may.

Ghép hai nhánh thành một hệ thống, và con số trên phải đọc lại. Hệ mà luận văn đề xuất không phải từng nhánh riêng mà là hai nhánh định tuyến theo điều kiện. Ghép chúng bằng cách nối dự đoán theo khoá (ca, tầng), không huấn luyện lại. Phép ghép này lập tức chạm vào lỗi chia tập nêu ở mục sau: hai tập validation chỉ chung **214 trên 395** bệnh nhân, nên chỉ chấm được trên phần giao đó — 181 bệnh nhân còn lại nằm trong tập huấn luyện của một trong hai nhánh.

Hệ quả là hai con số +0,054 và +0,039 ở Bảng 12 **không so trên cùng một nhóm bệnh nhân**. Khi so đúng cặp, trên cùng các dòng dữ liệu:

Bảng 13: AUPRC macro nhãn lỗi liên hợp, so trên 214 bệnh nhân cả hai nhánh đều giữ lại.

	Nhánh T2	Nhánh T1	Chênh
Lỗi trái	0,4767	0,5121	+0,035
Lỗi phải	0,5171	0,5099	−0,007

Bên trái vẫn dương nhưng nhỏ hơn con số đã báo; **bên phải mất hẳn**. Toàn hệ thống, Mean F1 macro là 0,5311 (chỉ T2) so với 0,5108 (có định tuyến), tức $-0,020$ với khoảng tin cậy 95% $[-0,046; +0,005]$ và $p = 0,122$: định tuyến **không cho thấy cải thiện**, mà cũng chưa đủ bằng chứng nói nó làm tệ đi.

Cả hai phép so đều nhiều — 214 bệnh nhân, một seed, mỗi điều kiện 40–48 ca Severe. Khác biệt là phép so này **hợp lệ**, còn phép so cũ bị nhiễu bởi việc bệnh nhân nào rơi vào tập nào. Vì vậy phát biểu đúng lúc này là: **giả thuyết định tuyến chưa được chứng minh**, và việc quyết định nó là chạy lại cả hai nhánh trên cùng một phép chia theo hàm băm. Mã tái lập ở `experiments/routing/assemble_routed_system.py`.

Kiểm chứng nguyên nhân. Nếu vùng ảnh thật sự không thấy được lỗi liên hợp thì mô hình cũ phải kém hơn ở đúng những ca đó. Kiểm trong nội bộ một mô hình, chia theo một thuộc tính của dữ liệu mà mô hình không biết:

Bảng 14: AUC lớp Severe của mô hình T2, chia theo vị trí nhãn.

	Trong 9 lát	Ngoài 9 lát	Chênh	p
Lỗ phải	0,8983	0,8321	+0,066	0,044
Lỗ trái	0,8685	0,8643	+0,004	0,903

Bên phải xác nhận, bên trái không. Hai bên khác nhau theo đúng hướng dự đoán: bên phải có 47,2% ca ngoài phạm vi so với 32,2% của bên trái, tức nhiều ca bị ảnh hưởng hơn thì hiệu ứng lớn hơn. **Giới hạn cần nêu:** đây là hai phép kiểm, một cái đạt $p = 0,044$; hiệu chỉnh cho việc so nhiều lần thì $p = 0,088$, nên kết luận đúng là **có dấu hiệu ủng hộ**, chưa phải bằng chứng chắc chắn.

5.3. Bốn hướng đã thử và không hiệu quả

Các kết quả âm dưới đây đều đáng báo cáo vì chúng loại bỏ những hướng nghe hợp lý.

Bảng 15: Các hướng cải thiện đã thử nghiệm và kết quả.

Hướng	Kết quả
Cơ chế trộn có cổng (gated fusion)	Chênh lệch đỉnh 0,0016, nhỏ hơn độ lệch chuẩn giữa các epoch (0,0048). Không khác biệt.
Trung bình trọng số nhiều epoch	Kém hơn epoch đơn tốt nhất ở mọi chỉ số. Không có tác dụng.
Mở băng tầng cuối của backbone	Quá khớp: Mean Accuracy +0,029 nhưng Severe AUPRC -0,037 . Quá khớp ăn vào lớp hiểm trước.
Bản đồ nhiệt (Grad-CAM) để định vị	Thua phép đoán “giữa ảnh”: 30,7 mm so với 21,6 mm. Không định vị được.

Kết quả mở băng backbone trở thành **lý lẽ bảo vệ** thiết kế đóng băng hiện tại, khi được hỏi “tại sao không tinh chỉnh toàn bộ mạng”.

6. Khả diễn giải: khảo sát và kiểm chứng

Theo yêu cầu khảo sát nhiều hướng tiếp cận, đã rà 16 phương pháp thuộc bốn họ: CAM dùng gradient, CAM không gradient, quy gán ở không gian đầu vào, và tín hiệu nội tại của mô hình. Chọn triển khai bốn phương pháp có **cơ chế khác nhau** thay vì nhiều biến thể cùng một cơ chế.

Hai kết quả kiểm chứng đáng lưu:

Grad-CAM trên nhánh CBAM là phân rã chính xác, không phải suy đoán. Đầu ra của mạng là gộp trung bình toàn cục rồi một tầng tuyến tính — đúng kiến trúc mà Draelos & Carin chứng minh CAM, HiResCAM và Grad-CAM cho cùng một kết quả. Kiểm bằng số trên mô hình của đề tài: tương quan Pearson **1,000000**, sai lệch tuyệt đối lớn nhất $2,4 \times 10^{-7}$.

Bản đồ nhiệt không định vị được lỗ liên hợp. Đo khoảng cách từ đỉnh bản đồ nhiệt tới điểm bác sĩ chấm, kèm hai mốc đối chứng bắt buộc:

Bảng 16: Khoảng cách tới điểm bác sĩ chấm (trung vị, mm), các ca Severe.

	Lỗ trái (n=53)	Lỗ phải (n=20)
Grad-CAM	30,7	33,9
Layer-CAM	31,8	30,4
Đoán ngẫu nhiên	49,7	53,7
Đoán giữa ảnh	21,6	19,6

Cả hai phương pháp thắng phép đoán ngẫu nhiên nhưng **thua phép đoán “giữa ảnh”**, nên chúng không

mang thông tin định vị hữu ích. Kết quả này trùng với Arun và cộng sự (*Radiology: AI*, 2021): cả 8 phương pháp họ thử trên ảnh y tế thật đều trượt ít nhất một tiêu chí tin cậy.

Hệ quả cần ghi nhận: hình Grad-CAM dùng trong bài báo đã nộp **không chứng minh được** điều nó tuyên bố. Vùng ống sống nằm ngay giữa ảnh do cách cắt, nên “mô hình tập trung vào ống sống” không phân biệt được với “mô hình tập trung vào giữa ảnh” — mốc đối chứng cho 0,4 mm trong khi Grad-CAM cho 14,0 mm.

7. Hội nghị MIWAI 2026: tài liệu đã chuẩn bị

Bài báo *A Two-Branch Hybrid Model for Imbalanced Lumbar Disc Grading and Zero-Shot Label Extension* (paper 122) đã được chấp nhận báo cáo miệng. Ban tổ chức yêu cầu **mọi bài** tham gia phiên bất đồng bộ, gồm ba món: phần tóm tắt, một trang infographic, và một video.

Bảng 17: Tài liệu hội nghị, trạng thái tại thời điểm báo cáo.

Tài liệu	Trạng thái
Tóm tắt	Xong, 247 từ, lấy nguyên văn từ bài đã chấp nhận
Infographic	Xong, một trang 1920×1080. Mọi số trên trang truy được về bảng trong bài báo
Video	Chưa quay. Slide và kịch bản nói là nguyên liệu
Slide báo cáo	Xong, 23 trang: 14 trang trình bày, 3 trang tài liệu tham khảo, 5 trang dự phòng
Kịch bản nói	Xong, bấm giờ từng slide, chạy 11–13 phút trong khung 15 phút

Slide và kịch bản **không phải món nộp** — chúng là nguyên liệu để quay video và để trình bày trực tuyến. Kịch bản kèm phần hỏi đáp đã soạn sẵn 11 câu, trong đó có hai câu khó nhất: vì sao độ chính xác tổng giảm, và vì sao trung bình tám nhãn zero-shot lại thua mô hình chưa huấn luyện.

Toàn bộ nằm ở `paper/camera_ready/miwai_async/`, đóng gói sẵn một tệp nén để gửi.

8. Số liệu chi tiết các phase trước

Mục này là phần tra cứu, không nằm trong mạch trình bày. Gom lại để khi cần một con số cụ thể thì mở đúng một chỗ, thay vì lật ba tệp.

8.1. Bốn cấu hình nội bộ

Bảng 18 là bốn cấu hình nội bộ, Bảng 19 tách tiếp theo từng điều kiện và từng mức độ. Mọi ô ở cả hai bảng đều **tính lại từ tệp số liệu lưu kèm mỗi lần chạy** trong `checkpoints/v3_20260503/`, nên truy ngược được về đúng lần chạy đã sinh ra chúng.

Ba ô trong bản trước bị sai và đã sửa ở đây. Hàng Severe Recall ghi 0,370 cho CBAM và 0,245 cho BMC-only, trong khi tệp số liệu cho 0,362 và **0,313**; sai lệch ở BMC-only là 6,8 điểm và làm cấu hình đó bị đánh giá thấp hơn thực tế. Hàng Mean F1 macro ghi 0,420 cho SpineNetV2 trong khi tệp cho 0,429 — 0,420 là con số 3 seed của bài báo, lọt vào một bảng vốn ghi rõ là seed 42. Các hàng Severe F1, Severe AUPRC và Mean AUC khớp chính xác.

8.2. Chi tiết theo từng bệnh và từng mức độ

Bảng 19 ở trên đã tách Recall, Precision và F1 theo điều kiện × lớp cho cả bốn cấu hình. Bảng 20 bổ sung hai chỉ số **không phụ thuộc ngưỡng** với cùng cách chia, để phân biệt phần cải thiện đến từ biểu diễn đặc trưng với phần đến từ việc dịch điểm cắt quyết định.

Bảng 18: Bốn cấu hình trên RSNA 2024 (seed 42), mọi ô tính lại từ tệp số liệu lưu kèm mỗi lần chạy.

Chỉ số	SpineNetV2	CBAM	BMC-only	Hybrid
Mean Accuracy	0,813	0,690	0,692	0,721
Mean Recall	0,417	0,569	0,528	0,591
Mean Precision	0,492	0,510	0,475	0,517
Mean F1 macro	0,429	0,502	0,463	0,528
Macro AUC	0,826	0,822	0,812	0,837
Macro AUPRC	0,523	0,519	0,482	0,526
<i>Lớp Severe</i>				
Severe Recall	0,115	0,362	0,313	0,464
Severe Precision	0,212	0,272	0,211	0,273
Severe F1	0,149	0,304	0,229	0,343
Severe AUC	0,860	0,886	0,874	0,896
Severe AUPRC	0,276	0,319	0,218	0,321

Bảng 19: Chi tiết theo điều kiện $\times$ mức độ cho cả bốn cấu hình (seed 42). Mỗi ô: Recall / Precision / F1.

Điều kiện	Mức độ	SpineNetV2	CBAM	BMC-only	Hybrid
Ổng sống	Normal/Mild	0,987 / 0,909 / 0,946	0,921 / 0,975 / 0,947	0,892 / 0,950 / 0,920	0,933 / 0,972 / 0,952
	Moderate	0,079 / 0,379 / 0,131	0,446 / 0,339 / 0,385	0,201 / 0,226 / 0,213	0,396 / 0,385 / 0,390
	Severe	0,346 / 0,636 / 0,448	0,716 / 0,436 / 0,542	0,691 / 0,277 / 0,396	0,704 / 0,388 / 0,500
Lỗ trái	Normal/Mild	0,950 / 0,812 / 0,875	0,619 / 0,920 / 0,740	0,609 / 0,933 / 0,737	0,599 / 0,926 / 0,727
	Moderate	0,242 / 0,470 / 0,319	0,683 / 0,294 / 0,411	0,753 / 0,301 / 0,430	0,675 / 0,292 / 0,408
	Severe	0,000 / 0,000 / 0,000	0,212 / 0,183 / 0,197	0,150 / 0,203 / 0,173	0,375 / 0,221 / 0,278
Lỗ phải	Normal/Mild	0,951 / 0,800 / 0,869	0,538 / 0,952 / 0,687	0,627 / 0,919 / 0,745	0,707 / 0,912 / 0,797
	Moderate	0,199 / 0,423 / 0,271	0,828 / 0,298 / 0,438	0,734 / 0,312 / 0,438	0,621 / 0,347 / 0,446
	Severe	0,000 / 0,000 / 0,000	0,157 / 0,197 / 0,174	0,096 / 0,154 / 0,119	0,313 / 0,211 / 0,252

Bảng 20: AUC / AUPRC theo điều kiện $\times$ lớp cho cả bốn cấu hình (seed 42). Mỗi ô: AUC / AUPRC.

Điều kiện	Lớp	SpineNetV2	CBAM	BMC-only	Hybrid
Ổng sống	Normal/Mild	0,892 / 0,984	0,947 / 0,993	0,874 / 0,981	0,946 / 0,993
	Moderate	0,851 / 0,272	0,884 / 0,319	0,783 / 0,203	0,872 / 0,299
	Severe	0,922 / 0,513	0,963 / 0,602	0,907 / 0,331	0,962 / 0,594
Lỗ trái	Normal/Mild	0,794 / 0,932	0,789 / 0,924	0,803 / 0,936	0,815 / 0,938
	Moderate	0,758 / 0,387	0,655 / 0,262	0,710 / 0,306	0,680 / 0,289
	Severe	0,815 / 0,147	0,858 / 0,174	0,854 / 0,169	0,869 / 0,174
Lỗ phải	Normal/Mild	0,802 / 0,929	0,807 / 0,931	0,808 / 0,934	0,823 / 0,939
	Moderate	0,760 / 0,375	0,657 / 0,283	0,705 / 0,325	0,708 / 0,312
	Severe	0,842 / 0,167	0,837 / 0,181	0,861 / 0,153	0,858 / 0,195

Lớp Severe tăng cả AUC lẫn AUPRC trên cả ba điều kiện khi đi từ SpineNetV2 sang Hybrid. Vì hai chỉ số này đánh giá thứ tự xếp hạng, kết quả loại trừ khả năng cải thiện chỉ là hệ quả của việc dịch ngưỡng.

Một chênh lệch với bảng trong luận văn, ghi lại để khỏi lẫn. Chương 5 luận văn ghi Severe Precision của Hybrid ở nhãn ống sống là 0,559, dẫn tới F1 0,623. Tập số liệu lưu kèm lần chạy cho **0,388** và F1 **0,500**; riêng Recall thì khớp chính xác ở 0,704. Báo cáo này dùng số trong tệp vì truy ngược được về đúng lần chạy. Cần rà lại chương 5 trước khi nộp luận văn.

9. Ba lỗi phương pháp đã phát hiện

Sai hệ tọa độ. Phép đo hình học ban đầu trừ tọa độ điểm ảnh của hai chuỗi T1 và T2 như thể chúng cùng một hệ. Ba trong bốn ca kiểm tra có lưới ảnh khác nhau (384×384 ở 0,78 mm so với 640×640 ở 0,47 mm). Tính lại trong không gian bệnh nhân thì lập luận vẫn đúng nhưng **đổi trực**: không phải “ngoài khung hình” mà là “ngoài độ sâu 9 lát”.

Sai phép chia tập bệnh nhân. Hàm chia chạy trên danh sách bệnh nhân của từng tệp mô tả dữ liệu; hai tệp lệch nhau 3 ca nên sinh ra hai phép chia hoàn toàn khác nhau. Hai tập validation chỉ chung 214 trên 395 bệnh nhân, và 181 bệnh nhân nằm ở tập kiểm của mô hình này lại nằm ở tập huấn luyện của mô hình kia. Việc này **không làm sai** số của từng mô hình, nhưng làm phép **so sánh** giữa chúng lỏng hơn mức đã trình bày. Đã sửa bằng cách chia theo hàm băm mã bệnh nhân, cho 406 bệnh nhân trùng khớp 100% giữa hai tập dữ liệu.

Chép nhầm ô trong bảng tóm tắt luận văn. Bảng tổng hợp bốn cấu hình ở chương 5 ghi Mean F1 macro là 0,343 $\rightarrow$ 0,474, và phần tóm tắt nhắc lại thành mức cải thiện +0,131. Tính lại chỉ số này từ bảng per-class nằm ngay cùng trang (F1 từng lớp 0,898 / 0,211 / 0,152 và 0,786 / 0,406 / 0,333) cho **0,4203 $\rightarrow$ 0,5083**. Giá trị nền tính lại khớp bốn chữ số thập phân với số 3 seed của bài báo (0,4202), nên 0,343 là sai — đó là Severe F1 của Hybrid, nằm cách hai dòng trong cùng bảng. Mức cải thiện thật là +0,088 (một seed) hoặc +0,106 (ba seed). Báo cáo này không bị ảnh hưởng vì đã dùng 0,420 $\rightarrow$ 0,528.

10. Kế hoạch tiếp theo

1. **Chạy lại hai nhánh trên cùng một phép chia** bằng chế độ băm mã bệnh nhân, rồi so trên đủ 395 bệnh nhân. Đây là việc *bắt buộc*, không phải tùy chọn: phát biểu “định tuyến T1 cải thiện nhãn lỗ liên hợp” hiện đứng trên một phép so không hợp lệ, và ghép hệ thống trên phần giao 214 bệnh nhân không cho thấy cải thiện. Cần GPU.
2. **Chạy 3 seed** cho cấu hình thắng, vì mọi số Phase 3 hiện là một seed trong khi Phase 2 dùng 3 seed. Không được trộn hai bộ số trong cùng một bảng.
3. **Quy công giữa hai nhánh** — do mô hình chỉ có hai nhánh nên giá trị Shapley tính được chính xác tuyệt đối chỉ với hai lượt suy luận thêm. Trả lời được nhánh nào quyết định kết quả.
4. **Sửa số liệu trong luận văn** — câu ở phần tóm tắt hiện ghi “Mean F1 macro từ 0,343 lên 0,474”; 0,343 thực chất là Severe F1, còn 0,474 không khớp tệp số liệu nào. Số đúng theo 3 seed là **0,4202 $\rightarrow$ 0,5265**, Severe Recall **12,3% $\rightarrow$ 48,6%**.
5. **Hoàn thiện phần mềm** — quay video minh họa, và xử lý phản hồi của thầy.