

Báo cáo tiến độ Phase 3

Ứng dụng AI trong gán nhãn ảnh y tế cho bệnh đau thắt lưng

Trung Kiên | GVHD: Phan Trọng Nhân

09/09/2026

1. Tóm tắt


Báo cáo tổng hợp kết quả Phase 3, đối chiếu với mốc đã trình bày trước hội đồng ở Phase 2. Ba nhóm việc đã hoàn thành: (i) hoàn thiện phần mềm gán nhãn có vòng phản hồi bác sĩ; (ii) bốn thực nghiệm GPU tìm hướng cải thiện lớp Severe; (iii) chẩn đoán nguyên nhân điểm yếu ở nhãn lỗ liên hợp và một khung đánh giá khả năng giải có kiểm chứng.

Kết quả đáng kể nhất là **chẩn đoán được nguyên nhân** khiến nhãn lỗ liên hợp (*neural foraminal narrowing*) luôn kém: quy trình cắt ảnh cũ lấy vùng ảnh từ chuỗi Sagittal T2 trong khi bác sĩ chấm nhãn này trên Sagittal T1, và đo trong không gian bệnh nhân cho thấy **32,2% (trái) và 47,2% (phải)** vùng cần chấm nằm ngoài độ sâu ảnh mà mô hình được cho. Sau khi cắt riêng theo từng bên trên T1, AUPRC lỗ liên hợp tăng **+0,054** và **+0,039** so với Phase 2.

Báo cáo cũng ghi lại bốn kết quả âm và hai lỗi phương pháp đã phát hiện, vì chúng ảnh hưởng tới cách diễn giải số liệu cũ.


2. Phần mềm gán nhãn

Ứng dụng web (FastAPI + React/Cornerstone3D) cho phép tải ảnh MRI, xem theo lát, chạy mô hình chấm 11 nhãn bất thường, và **ghi nhận chỉnh sửa của bác sĩ như phản hồi chuyên gia**. Quy mô hiện tại: 16.426 dòng Python, 2.452 dòng frontend, 24 tệp kiểm thử.



Hình 1: Màn hình danh sách ca. Mỗi bệnh nhân có thể chứa nhiều lần chụp; trạng thái *Ready* nghĩa là ảnh đã tải xong và sẵn sàng chấm.

Điểm thiết kế đáng lưu ý ở Hình 2: chỉnh sửa của bác sĩ **không tác động ngay** tới mô hình. Chúng được xếp hàng, việc huấn luyện lại chạy ngoại tuyến, và phiên bản mô hình mới phải được duyệt rồi mới kích hoạt. Điều này tránh tình huống kết quả của bệnh nhân sau bị thay đổi bởi chỉnh sửa của bệnh nhân trước.



Hình 2: Màn hình đọc ảnh, hiển thị chuỗi Sagittal T2 ($512 \times 512 \times 17$, $0,586 \times 0,586 \times 3,3$ mm). Bảng *Abnormality grades* nằm dưới ảnh cho phép bác sĩ sửa từng nhãn; khối *Doctor feedback* bên phải gom các chỉnh sửa thành hàng đợi huấn luyện.

3. Mốc Phase 2 đã trình bày hội đồng

3.1. Bốn cấu hình nội bộ

Bảng 1 là số đã báo cáo, giữ nguyên để đối chiếu.

Bảng 1: Bốn cấu hình trên RSNA 2024 (seed 42), số đã trình bày ở Phase 2.

Chỉ số	SpineNetV2	CBAM	BMC-only	Hybrid
Mean Accuracy	0,814	0,690	0,692	0,721
Mean F1 (macro)	0,420	0,502	0,464	0,528
Mean AUC	0,826	0,822	0,812	0,837
<i>Lớp Severe</i>				
Severe Recall	0,115	0,370	0,245	0,464
Severe F1	0,149	0,304	0,229	0,343
Severe AUPRC	0,276	0,319	0,218	0,321

3.2. So sánh với phương pháp ngoài

Hai phương pháp ngoài được huấn luyện lại trên **đúng cùng phép chia bệnh nhân** (seed 42/123/456, chia 80/20 theo mã ca) và đánh giá trên cùng ba nhãn, để so sánh công bằng.

Bảng 2: Các cấu hình đem so sánh.

Cấu hình	Kiến trúc	Nguồn
SpineNetV2	3D-ResNet34	nền so sánh của đề tài
brendanartley	CNN 2.5D + BiLSTM + gộp có chú ý	hạng nhì RSNA 2024, cài đặt lại
transformer	CNN 2.5D + bộ mã hoá Transformer	kiểu gộp Transformer 2024
Hybrid	CBAM-3D + BiomedCLIP, đầu ra theo mô tả văn bản	của đề tài

Bảng 3: Kết quả trên RSNA 2024, trung bình $\pm$ độ lệch chuẩn qua 3 seed.

Chỉ số	SpineNetV2	brendanartley	transformer	Hybrid
Mean Accuracy (%)	81,0 $\pm$ 0,6	83,6 $\pm$ 0,5	83,4 $\pm$ 0,4	72,4 $\pm$ 0,3
Mean F1 (macro)	0,420 $\pm$ 0,010	0,532 $\pm$ 0,008	0,527 $\pm$ 0,028	0,527 $\pm$ 0,027
<i>Lớp Severe — lớp có ý nghĩa lâm sàng</i>				
Severe F1	0,152 $\pm$ 0,008	0,271 $\pm$ 0,026	0,257 $\pm$ 0,020	0,356 $\pm$ 0,017
Severe Recall (%)	12,3 $\pm$ 0,6	26,0 $\pm$ 1,6	25,9 $\pm$ 2,8	48,6 $\pm$ 1,9

Bảng 3 cho thấy một sự đánh đổi rõ ràng. Hybrid **thua khoảng 11 điểm Accuracy** và ngang bằng về Mean F1, nhưng ở lớp Severe thì dẫn đầu rõ rệt: Severe Recall **48,6%** so với 26,0% và 25,9%, tức **gần gấp đôi** phương pháp ngoài tốt nhất; Severe F1 **0,356** so với 0,271.

Đánh đổi này là có chủ ý. Hai phương pháp ngoài đạt Accuracy cao bằng cách thiên về lớp đa số (Normal/Mild chiếm phần lớn dữ liệu), trong khi ca bỏ sót ở lớp Severe mới là ca gây hậu quả lâm sàng. Với bài toán sàng lọc, bỏ sót ba trong bốn ca nặng để đổi lấy Accuracy đẹp hơn là đánh đổi sai hướng.

Ngoài chỉ số, Hybrid còn có ba khả năng mà cả ba phương pháp kia đều không có, do chúng dùng đầu ra cố định:

Bảng 4: So sánh khả năng mở rộng tập nhân.

Khả năng	SpineNetV2	2 phương pháp ngoài	Hybrid
Nhận tập nhân mới làm đầu vào	không	không	có
Chuyển sang bộ dữ liệu khác (SPIDER)	phải huấn luyện lại	phải huấn luyện lại	có
Dự đoán nhân chưa từng thấy	không	không	có

Ghi chú về tính công bằng của phép so sánh. Hai phương pháp ngoài là **cài đặt lại phần lõi kiến trúc chấm điểm**, đã điều chỉnh để nhận cùng dạng vùng ảnh (9, 112, 224) của đề tài — **không phải** pipeline đầu-cuối từ ảnh DICOM của tác giả gốc. Cả hai cũng huấn luyện từ đầu vì không có trọng số tiền huấn luyện tương thích, trong khi Hybrid dùng backbone đã tiền huấn luyện. Con số vì vậy phản ánh so sánh kiến trúc trên cùng biểu diễn dữ liệu, không phải so sánh hai hệ thống hoàn chỉnh.

4. Thực nghiệm Phase 3

4.1. Sửa lỗi khởi tạo: nền so sánh sạch

Hai thực nghiệm trước đó dùng nhằm checkpoint khởi tạo (không có trọng số lớp). Chạy lại đúng công thức đã công bố trên checkpoint đúng cho kết quả ở Bảng 5. Đây là **sửa lỗi, không phải đóng góp** — giá trị của nó là mọi so sánh về sau không bị bác bằng câu “nền so sánh của em hỏng”.

Bảng 5: Cùng công thức, khác checkpoint khởi tạo (seed 42, cùng tập validation).

Chỉ số	Phase 2	Khởi tạo đúng	Chênh
Severe AUPRC	0,3211	0,3696	+0,0485
Severe F1	0,3434	0,3696	+0,0262
Mean Accuracy	0,7208	0,7318	+0,0110
Mean F1 (macro)	0,5277	0,5286	+0,0009
Macro AUPRC	0,5258	0,5364	+0,0106
Macro AUC	0,8371	0,8368	−0,0003

Bảng 6 tách theo từng nhân, và đây mới là chỗ giải thích vì sao phải làm bước tiếp theo.

Ổng sống cải thiện rõ (Severe Recall **+0,136**), nhưng **hai nhân lỗi liên hợp gần như đứng yên** — AUPRC

Bảng 6: Kết quả từng nhãn, Phase 2 so với khởi tạo đúng (seed 42, cùng tập validation).

	Phase 2	Khởi tạo đúng	Chênh
<i>Ổng sống</i>			
Severe F1	0,5000	0,5714	+0,0714
Severe Recall	0,7037	0,8395	+0,1358
AUPRC	0,6284	0,6506	+0,0222
<i>Lỗ liên hợp trái</i>			
AUPRC	0,4670	0,4709	+0,0039
Severe F1	0,2778	0,2887	+0,0109
<i>Lỗ liên hợp phải</i>			
AUPRC	0,4820	0,4878	+0,0058
Severe F1	0,2524	0,2486	-0,0038

chỉ nhích 0,004 và 0,006. Sửa khởi tạo không chạm được tới điểm yếu này, nghĩa là nguyên nhân nằm ở chỗ khác. Đó là điều dẫn tới phần tiếp theo.

4.2. Chuyên gia T1 cho nhãn lỗ liên hợp: đóng góp chính

Chẩn đoán. Đối chiếu tập toạ độ với mô tả chuỗi ảnh: nhãn lỗ liên hợp được chấm **100% trên Sagittal T1**, nhãn ống sống **99,9% trên Sagittal T2**, và hai loại chỉ dùng chung một chuỗi **1 lần trên 6291** ca. Quy trình cũ cắt một vùng ảnh duy nhất từ T2 lấy tâm theo toạ độ ống sống rồi gắn cả ba nhãn.

Đo độ lệch trong **không gian bệnh nhân** của DICOM (dùng ImagePositionPatient và ImageOrientationPatient, không so toạ độ điểm ảnh vì hai chuỗi có lưới khác nhau):

Bảng 7: Vị trí nhãn lỗ liên hợp so với vùng ảnh cắt từ T2 (796 cặp, 80 ca).

	Lỗ trái	Lỗ phải
Lệch trong mặt phẳng (trung vị)	9,7 mm	9,9 mm
Nằm ngoài khung ảnh theo mặt phẳng	0,3%	0,3%
Lệch theo chiều sâu (trung vị)	4,0 lát	4,0 lát
Nằm ngoài độ sâu 9 lát	32,2%	47,2%

Khung ảnh theo mặt phẳng rất rộng (nửa cạnh 70×35 mm) nên hầu như luôn phủ được. Chỗ hụt là **độ sâu**: vùng ảnh chỉ gồm 9 lát, trong khi gần một nửa số ca bên phải có vùng cần chấm nằm ngoài phạm vi đó. Nói cách khác, mô hình được yêu cầu chấm một cấu trúc **không có trong ảnh đầu vào**.

Kết quả sau khi sửa. Cắt vùng ảnh riêng cho từng bên trên chuỗi T1, lấy tâm theo toạ độ của chính bên đó:

Bảng 8: AUPRC nhãn lỗ liên hợp. Cột “đỉnh” là epoch tốt nhất trong 20 epoch.

	Phase 2	Chuyên gia T1	Chênh	Đỉnh ep16
<i>AUPRC — chỉ số xếp hạng, không phụ thuộc ngưỡng</i>				
Lỗ trái	0,4670	0,5205	+0,054	0,5321
Lỗ phải	0,4820	0,5209	+0,039	0,5311
<i>AUC</i>				
Lỗ trái	0,7880	0,8165	+0,029	0,8281
Lỗ phải	0,7964	0,8147	+0,018	0,8268
<i>Severe F1 — phụ thuộc ngưỡng argmax</i>				
Lỗ trái	0,2778	0,2247	-0,053	—
Lỗ phải	0,2524	0,2902	+0,038	—

Severe F1 lỗ trái lại giảm, và điều này cần giải thích chứ không nên bỏ qua. AUPRC tăng trong khi F1

giảm nghĩa là mô hình **xếp hạng ca nặng tốt hơn nhưng điểm cắt argmax chưa khai thác được lợi thế đó**. Đây đúng là việc mà tinh chỉnh ngưỡng giải quyết: đo bằng kiểm chéo theo nửa bệnh nhân, chỉnh trọng số quyết định từng lớp nâng macro F1 từ 0,468 lên **0,509 (+0,041)** trên phần dữ liệu giữ lại. Trên mô hình Phase 2 cùng phương pháp cho **+0,019**. Hai cải thiện này cộng dồn được vì chúng tác động vào hai khâu khác nhau — một cái cải thiện biểu diễn, một cái cải thiện quy tắc quyết định.

Điều đáng tin hơn con số: **cả 20/20 epoch** của mô hình T1 đều vượt epoch tốt nhất trong 20 epoch của mô hình cũ, ở cả hai bên, không ngoại lệ. Tính nhất quán này loại trừ khả năng vớ được một epoch may.

Kiểm chứng nguyên nhân. Nếu vùng ảnh thật sự không thấy được lỗi liên hợp thì mô hình cũ phải kém hơn ở đúng những ca đó. Kiểm trong nội bộ một mô hình, chia theo một thuộc tính của dữ liệu mà mô hình không biết:

Bảng 9: AUC lớp Severe của mô hình T2, chia theo vị trí nhãn.

	Trong 9 lát	Ngoài 9 lát	Chênh	p
Lỗ phải	0,8983	0,8321	+0,066	0,044
Lỗ trái	0,8685	0,8643	+0,004	0,903

Bên phải xác nhận, bên trái không. Hai bên khác nhau theo đúng hướng dự đoán: bên phải có 47,2% ca ngoài phạm vi so với 32,2% của bên trái, tức nhiều ca bị ảnh hưởng hơn thì hiệu ứng lớn hơn. **Giới hạn cần nêu:** đây là hai phép kiểm, một cái đạt $p = 0,044$; hiệu chỉnh cho việc so nhiều lần thì $p = 0,088$, nên kết luận đúng là **có dấu hiệu ủng hộ**, chưa phải bằng chứng chắc chắn.

4.3. Một bằng chứng độc lập: mức đồng thuận so với bác sĩ

Chẩn đoán ở trên dựa vào hình học và vào kết quả của mô hình. Có một cách kiểm tra thứ ba, không dùng cả hai: so **mức đồng thuận** của mô hình với mức đồng thuận **giữa các bác sĩ với nhau**, đo bằng cùng một chỉ số là Cohen’s kappa có trọng số bậc hai (QWK).

Bảng 10: QWK của mô hình Phase 2 so với đồng thuận giữa bác sĩ (Lurie và cộng sự, *Spine*, 2008).

	Mô hình	Giữa các bác sĩ
Ổng sống	0,641	0,73
Lỗ liên hợp trái	0,351	0,58
Lỗ liên hợp phải	0,409	0,58

Mô hình **gần chạm mức bác sĩ ở ống sống** (0,641 so với 0,73) nhưng **kém xa ở lỗ liên hợp** (0,351 so với 0,58). Đáng chú ý là kết luận này đến từ một hướng hoàn toàn khác — không dùng tọa độ, không dùng hình học, không dùng bản đồ nhiệt — mà vẫn chỉ đúng một chỗ yếu. Ba phép đo độc lập cùng chỉ vào nhãn lỗ liên hợp thì khó quy cho ngẫu nhiên.

Toàn bộ chỉ số của Phase 2 kèm khoảng tin cậy bootstrap phân cụm theo bệnh nhân (2000 lần rút):

Bảng 11: Mô hình Phase 2, khoảng tin cậy 95% phân cụm theo bệnh nhân.

Chỉ số	Giá trị	KTC 95%
Severe F1	0,3434	[0,292 — 0,392]
Severe AUPRC	0,3211	[0,280 — 0,371]
Severe Recall	0,4640	[0,399 — 0,532]
QWK	0,4670	[0,432 — 0,499]
Weighted log loss	0,7549	[0,736 — 0,773]

Khoảng tin cậy của Severe F1 rộng **0,100** — đây là lý do báo cáo dùng AUPRC làm chỉ số chính khi so hai mô hình: với chỉ 80 ca nặng mỗi nhãn, Severe F1 không đủ độ phân giải để phân định, còn AUPRC ổn định hơn khoảng sáu lần giữa các epoch.

4.4. Bốn hướng đã thử và không hiệu quả

Các kết quả âm dưới đây đều đáng báo cáo vì chúng loại bỏ những hướng nghe hợp lý.

Bảng 12: Các hướng cải thiện đã thử nghiệm và kết quả.

Hướng	Kết quả
Cơ chế trộn có cổng (gated fusion)	Chênh lệch đỉnh 0,0016, nhỏ hơn độ lệch chuẩn giữa các epoch (0,0048). Không khác biệt.
Trung bình trọng số nhiều epoch	Kém hơn epoch đơn tốt nhất ở mọi chỉ số. Không có tác dụng.
Mở băng tầng cuối của backbone	Quá khớp: Mean Accuracy +0,029 nhưng Severe AUPRC -0,037 . Quá khớp ăn vào lớp hiểm trước.
Bản đồ nhiệt (Grad-CAM) để định vị	Thua phép đoán “giữa ảnh”: 30,7 mm so với 21,6 mm. Không định vị được.

Kết quả mở băng backbone trở thành **lý lẽ bảo vệ** thiết kế đóng băng hiện tại, khi được hỏi “tại sao không tinh chỉnh toàn bộ mạng”.

5. Khả diễn giải: khảo sát và kiểm chứng

Theo yêu cầu khảo sát nhiều hướng tiếp cận, đã rà 16 phương pháp thuộc bốn họ: CAM dùng gradient, CAM không gradient, quy gán ở không gian đầu vào, và tín hiệu nội tại của mô hình. Chọn triển khai bốn phương pháp có **cơ chế khác nhau** thay vì nhiều biến thể cùng một cơ chế.

Hai kết quả kiểm chứng đáng lưu:

Grad-CAM trên nhánh CBAM là phân rã chính xác, không phải suy đoán. Đầu ra của mạng là gộp trung bình toàn cục rồi một tầng tuyến tính — đúng kiến trúc mà Draelos & Carin chứng minh CAM, HiResCAM và Grad-CAM cho cùng một kết quả. Kiểm bằng số trên mô hình của đề tài: tương quan Pearson **1,000000**, sai lệch tuyệt đối lớn nhất $2,4 \times 10^{-7}$.

Bản đồ nhiệt không định vị được lỗ liên hợp. Đo khoảng cách từ đỉnh bản đồ nhiệt tới điểm bác sĩ chấm, kèm hai mốc đối chứng bắt buộc:

Bảng 13: Khoảng cách tới điểm bác sĩ chấm (trung vị, mm), các ca Severe.

	Lỗ trái (n=53)	Lỗ phải (n=20)
Grad-CAM	30,7	33,9
Layer-CAM	31,8	30,4
Đoán ngẫu nhiên	49,7	53,7
Đoán giữa ảnh	21,6	19,6

Cả hai phương pháp thắng phép đoán ngẫu nhiên nhưng **thua phép đoán “giữa ảnh”**, nên chúng không mang thông tin định vị hữu ích. Kết quả này trùng với Arun và cộng sự (*Radiology: AI*, 2021): cả 8 phương pháp họ thử trên ảnh y tế thật đều trượt ít nhất một tiêu chí tin cậy.

Hệ quả cần ghi nhận: hình Grad-CAM dùng trong bài báo đã nộp **không chứng minh được** điều nó tuyên bố. Vùng ống sống nằm ngay giữa ảnh do cách cắt, nên “mô hình tập trung vào ống sống” không phân biệt được với “mô hình tập trung vào giữa ảnh” — mốc đối chứng cho 0,4 mm trong khi Grad-CAM cho 14,0 mm.

6. Hai lỗi phương pháp đã phát hiện

Sai hệ tọa độ. Phép đo hình học ban đầu trừ tọa độ điểm ảnh của hai chuỗi T1 và T2 như thể chúng cùng một hệ. Ba trong bốn ca kiểm tra có lưới ảnh khác nhau (384×384 ở 0,78 mm so với 640×640 ở 0,47 mm).

Tính lại trong không gian bệnh nhân thì lập luận vẫn đúng nhưng **đổi trực**: không phải “ngoài khung hình” mà là “ngoài độ sâu 9 lát”.

Sai phép chia tập bệnh nhân. Hàm chia chạy trên danh sách bệnh nhân của từng tập mô tả dữ liệu; hai tập lệch nhau 3 ca nên sinh ra hai phép chia hoàn toàn khác nhau. Hai tập validation chỉ chung 214 trên 395 bệnh nhân, và 181 bệnh nhân nằm ở tập kiểm của mô hình này lại nằm ở tập huấn luyện của mô hình kia. Việc này **không làm sai** số của từng mô hình, nhưng làm phép **so sánh** giữa chúng lỏng hơn mức đã trình bày. Đã sửa bằng cách chia theo hàm băm mã bệnh nhân, cho 406 bệnh nhân trùng khớp 100% giữa hai tập dữ liệu.

7. Kế hoạch tiếp theo

1. **Ghép hệ định tuyến đầu-cuối** — lấy nhãn ống sống từ nhánh T2 và nhãn lỗ liên hợp từ nhánh T1 thành một hệ thống. Không cần huấn luyện lại, chỉ cần nối dự đoán theo khoá (ca, tầng). Cho ra Mean F1 macro ba điều kiện để đặt cạnh Phase 2 — con số hiện còn thiếu.
2. **Chạy 3 seed** cho cấu hình thắng, vì mọi số Phase 3 hiện là một seed trong khi Phase 2 dùng 3 seed. Không được trộn hai bộ số trong cùng một bảng.
3. **Quy công giữa hai nhánh** — do mô hình chỉ có hai nhánh nên giá trị Shapley tính được chính xác tuyệt đối chỉ với hai lượt suy luận thêm. Trả lời được nhánh nào quyết định kết quả.
4. **Sửa số liệu trong luận văn** — câu ở phần tóm tắt hiện ghi “Mean F1 macro từ 0,343 lên 0,474”; 0,343 thực chất là Severe F1, còn 0,474 không khớp tập số liệu nào. Số đúng theo 3 seed là **0,4202** → **0,5265**, Severe Recall **12,3%** → **48,6%**.
5. **Hoàn thiện phần mềm** — quay video minh hoạ, và xử lý phản hồi của thầy.